

計算最適輸送

2026 年 4 月 10 日

概要

本書は、Peyré-Cuturi による “Computational Optimal Transport” に基づき、最適輸送の理論と計算手法を体系的に解説するものである。

目次

第 1 章	はじめに	2
1.1	最適輸送とは何か	2
1.2	歴史的背景	3
1.3	本書の構成	5
第 2 章	理論的基礎	6
2.1	基本的な定義	6
2.2	最適割当問題と Monge 問題	17
2.3	Kantorovich 緩和の概要	20
2.4	Wasserstein 距離の概要	24
2.5	双対問題	26
2.6	特殊な場合	30
2.7	Brenier の定理	33
第 3 章	アルゴリズムの基礎	35
3.1	Kantorovich 問題の標準形	35
3.2	離散 C -変換	36
3.3	輸送多面体の頂点	37
3.4	北西隅法	38
3.5	ネットワーク単体法	38
3.6	オークションアルゴリズム	39
3.7	双対上昇法	41
第 4 章	エントロピー正則化	43
4.1	エントロピー正則化	43
4.2	Sinkhorn アルゴリズム	45
4.3	収束性	46
4.4	数値安定性と対数領域計算	47
4.5	正則化された輸送コストの近似	48

第 1 章

はじめに

1.1 最適輸送とは何か

科学や日常生活における多くの意思決定は、**最短経路の原理**に導かれている。ある地点にある品物を別の地点に届けたいとき、最も少ない労力で済む方法を選ぶのは自然な発想であり、平面上であれば直線に沿って、より一般の距離空間であれば測地線に沿って移動させることがこれに当たる。

最適輸送 (optimal transport; OT) の理論は、この直感を大きく一般化する。すなわち、1 つの品物だけを運ぶのではなく、**複数の品物** (あるいはその連続的な分布) をある配置から別の配置へと同時に移動させる問題を扱う。1 人の個人を目的地に送ることは単純であるが、集団全体を別の配置へ移動させ、しかも到着時に所定の分布が実現されるようにすることは、はるかに複雑な問題となる。この問題を数学的に定式化するには、測度論・凸最適化・線形計画法などの道具が必要となる。

以下に、最適輸送の概念を直感的に把握するための 2 つの具体例を挙げる。

例 1.1.1: 砂山の移動 — Monge の原問題

地面のある場所に砂山 (土砂の山) があり、これを掘り返して別の場所に所定の形状で盛り上げたいとする。砂の総量は保存されるものとする (掘り出した砂の総量 = 盛り上げた砂の総量)。

このとき、「どの砂粒をどこに運ぶか」という輸送計画を立て、輸送にかかる**総コスト** (= (各砂粒の質量) $\times$ (移動距離) の総和) を最小化する問題が、1781 年に Monge が提唱した最適輸送の原問題である。

ここで重要な点は、各砂粒は **1 つの行き先** にしか運べないという制約である。すなわち、砂粒を分割して複数の場所に送ることは許されない。

例 1.1.2: 工場と倉庫の輸送計画 — Hitchcock–Kantorovich 問題

n 箇所の倉庫がそれぞれ供給量 $a_1, \dots, a_n$ の商品を保有し、 m 箇所の工場がそれぞれ需要量 $b_1, \dots, b_m$ の商品を必要としているとする。供給量の合計と需要量の合計は等しいと仮定する： $\sum_{i=1}^n a_i = \sum_{j=1}^m b_j$ 。

倉庫 i から工場 j へ 1 単位の商品を輸送するコストが $C_{i,j} \geq 0$ で与えられているとき、輸送計画

$P_{i,j} \geq 0$ (倉庫 i から工場 j へ送る量) を求めて、**総輸送コスト**

$$\sum_{i=1}^n \sum_{j=1}^m C_{i,j} P_{i,j}$$

を最小化したい。ただし、供給制約 $\sum_{j=1}^m P_{i,j} = a_i$ と需要制約 $\sum_{i=1}^n P_{i,j} = b_j$ を満たす必要がある。この定式化では、Monge の問題と異なり、1 つの倉庫の商品を**複数の工場に分割して送る**ことが許される。これは Kantorovich による緩和の考え方に対応しており、問題が線形計画問題となるため、効率的に解くことが可能となる。

以上の例が示すように、最適輸送は、「品物の分布」どうしを比較し、一方の分布を他方の分布に変換するための最小コストを求めるという枠組みである。この最小コストは、確率分布の空間に自然な**距離** (Wasserstein 距離) を定め、機械学習・画像処理・統計学・経済学など多くの分野で強力なツールとなっている。

1.2 歴史的背景

最適輸送の理論は約 240 年にわたる歴史を持つ。以下に主要な発展を概観する。

Monge (1781)

最適輸送の起源は、フランスの数学者 Gaspard Monge が 1781 年に発表した “Mémoire sur la théorie des déblais et des remblais” (土砂の切り盛りに関する覚書) に遡る。Monge は、ある場所から掘り出した土砂を別の場所に運んで盛り上げるとき、総輸送コストを最小にする方法を求める問題を定式化した。この定式化では、各々の土砂の微小部分は**決定論的に** 1 つの行き先に送られる。すなわち、輸送は写像 $T: \mathcal{X} \rightarrow \mathcal{Y}$ によって記述される (2.2 節で詳述)。

しかしながら、Monge の定式化には数学的な困難がある。実行可能な写像の集合は一般に凸でなく、また実行可能な写像が存在しない場合すらある (2.2 節の例 2.2.11 を参照)。このため、Monge の問題は長い間未解決のまま残された。

Tolstoi (1930) と Hitchcock (1941)

20 世紀に入り、最適輸送は実用的な文脈で再発見された。Tolstoi (1930) はソビエト連邦における輸送ネットワークの最適化を研究し、Hitchcock (1941) は独立に工場・倉庫間の輸送問題を線形計画として定式化した。これらの研究は、最適輸送が純粋数学のみならず、物流・生産計画・ネットワーク設計といった応用上の重要な問題であることを示した。

Kantorovich (1942)

ソビエトの数学者・経済学者 Leonid Kantorovich (1975 年ノーベル経済学賞受賞) は、1942 年に最適輸送問題の革命的な再定式化を提案した。Monge の定式化では輸送が決定論的な写像 T で記述されるのに対し、Kantorovich は輸送を**カップリング測度** π (結合確率測度) で記述する**緩和**を導入した (2.3 節で詳述)。

この緩和の核心的な意義は以下の点にある：

- カップリング測度の集合は**凸集合**であり、目的関数はそれに関して線形である。
- したがって、Kantorovich の定式化は**線形計画問題**であり、常に解が存在する。
- さらに、線形計画の双対理論から**双対問題**が得られ、これは最適輸送の幾何学的理解に重要な役割を果たす。

Brenier (1991) と現代の発展

1991 年に Yann Brenier は、 $\mathbb{R}^d$ 上の二次コスト $c(x, y) = \|x - y\|_2^2$ に対して、最適輸送写像が存在し、凸関数の勾配として一意的に表されることを証明した (Brenier の定理)。この結果は、最適輸送を**凸解析**、**偏微分方程式** (Monge–Ampère 方程式)、**流体力学**と深く結びつけ、最適輸送の理論を飛躍的に発展させた。

21 世紀に入ると、計算手法の進展 (特に Sinkhorn アルゴリズムによるエントロピー正則化) により、最適輸送は大規模な実データにも適用可能となった。現在では、画像処理 (テクスチャ合成, 色転写)、機械学習 (生成モデル, ドメイン適応)、自然言語処理、計算生物学、経済学など幅広い分野で活用されている。

記法

- $\llbracket n \rrbracket$: 整数の集合 $\{1, \dots, n\}$.
- $\mathbf{1}_{n,m}$: すべての成分が 1 である $\mathbb{R}^{n \times m}$ 上の行列. $\mathbf{1}_n$: すべての成分が 1 の n 次元ベクトル.
- $\mathbf{I}_n$: $n \times n$ 単位行列.
- $\text{diag}(\mathbf{u})$: ベクトル $\mathbf{u} \in \mathbb{R}^n$ に対し、対角成分が $u_1, \dots, u_n$ で非対角成分が 0 の $n \times n$ 行列.
- Σ_n : n 次元確率単体. すなわち $\mathbb{R}_+^n$ における確率ベクトルの集合 $\{\mathbf{a} \in \mathbb{R}_+^n \mid \sum_i a_i = 1\}$.
- $(\mathbf{a}, \mathbf{b})$: 確率単体 $\Sigma_n \times \Sigma_m$ に属するヒストグラム.
- (α, β) : 空間 $(\mathcal{X}, \mathcal{Y})$ 上の測度.
- $\frac{d\alpha}{d\beta}$: 測度 α の β に関する相対密度 (ラドン–ニコディム導関数).
- $\rho_\alpha = \frac{d\alpha}{dx}$: ルベグ測度に関する測度 α の密度.
- $\left(\alpha = \sum_i a_i \delta_{x_i}, \beta = \sum_j b_j \delta_{y_j}\right)$: 台 $x_1, \dots, x_n \in \mathcal{X}$ および $y_1, \dots, y_m \in \mathcal{Y}$ 上の離散測度.
- $c(x, y)$: 基底コスト関数. 対応するペアワイズコスト行列 $C_{i,j} = c(x_i, y_j)$.
- π : α と β のカップリング測度. 離散測度に対しては $\pi = \sum_{i,j} P_{i,j} \delta_{(x_i, y_j)}$ であり、輸送行列 $\mathbf{P}$ として記述される.
- $\mathcal{U}(\alpha, \beta)$: カップリング測度の集合. 離散版は $\mathbf{U}(\mathbf{a}, \mathbf{b})$.
- $T: \mathcal{X} \rightarrow \mathcal{Y}$: Monge 写像. $T_\# \alpha = \beta$ を満たす.
- $(\mathbf{f}, \mathbf{g})$: 双対変数 (双対ポテンシャル).
- $\mathbf{L}_C(\mathbf{a}, \mathbf{b})$ および $\mathcal{L}_c(\alpha, \beta)$: コスト $\mathbf{C}$ (ヒストグラム) および c (任意の測度) に対する最適輸送問題の最適値.
- $\mathbf{W}_p(\mathbf{a}, \mathbf{b})$ および $\mathcal{W}_p(\alpha, \beta)$: 距離行列 $\mathbf{D}$ (ヒストグラム) および距離 d (任意の測度) に対する p -Wasserstein 距離.
- $\langle \cdot, \cdot \rangle$: ベクトルに対してはユークリッド内積. 同じサイズの行列 A, B に対しては $\langle A, B \rangle \stackrel{\text{def}}{=} \text{tr}(A^\top B)$ (フロベニウス内積).
- $f \oplus g(x, y) \stackrel{\text{def}}{=} f(x) + g(y)$: 関数 $f: \mathcal{X} \rightarrow \mathbb{R}, g: \mathcal{Y} \rightarrow \mathbb{R}$ に対する直和. 離散版では $\mathbf{f} \oplus \mathbf{g} \stackrel{\text{def}}{=} \mathbf{f} \mathbf{1}_m^\top + \mathbf{1}_n \mathbf{g}^\top \in \mathbb{R}^{n \times m}$.

- $\alpha \otimes \beta : \mathcal{X} \times \mathcal{Y}$ 上の積測度. すなわち $\int_{\mathcal{X} \times \mathcal{Y}} h(x, y) d(\alpha \otimes \beta)(x, y) = \int_{\mathcal{X}} \int_{\mathcal{Y}} h(x, y) d\beta(y) d\alpha(x)$.
- $\mathbf{a} \otimes \mathbf{b} \stackrel{\text{def}}{=} \mathbf{ab}^\top \in \mathbb{R}^{n \times m}$: ベクトルの外積.
- $\mathbf{u} \odot \mathbf{v} = (u_i v_i)_i \in \mathbb{R}^n$: ベクトルのアダマール積 (成分ごとの積).

1.3 本書の構成

本書の以降の章は次のように構成されている.

- 第2章：理論的基礎** 距離空間・測度・確率測度などの基本概念を定義した上で, Monge 問題, Kantorovich 緩和, Wasserstein 距離を定式化する.
- 第3章：基本アルゴリズム** 離散最適輸送を解くための古典的アルゴリズムを扱う. ネットワーク単体法, ハンガリアン法, オークションアルゴリズムなど, 線形計画に基づく手法を解説する.
- 第4章：エントロピー正則化** 大規模な最適輸送問題を効率的に近似解法する鍵となるエントロピー正則化を導入する. Sinkhorn アルゴリズムの導出・収束性・実装を詳述する.
- 第5章：半離散最適輸送** 離散測度と連続測度の間の最適輸送を扱う. ラゲール図 (Laguerre diagram) との関係を論じる.
- 第6章： W_1 最適輸送** 基底コストが距離そのものである場合の特別な構造を利用する手法を扱う. Beckmann 定式化, 双対表現 (リプシッツ制約), 最小コストフローとの関連を論じる.
- 第7章：動的定式化** Benamou–Brenier の流体力学的定式化を導入する. 変位補間 (displacement interpolation) と勾配流 (gradient flow) を扱う.
- 第8章：統計的側面** Wasserstein 距離の統計的推定に関する問題を扱う. サンプル複雑度, ミニマックスレートなどを論じる.
- 第9章：変分問題** Wasserstein 空間上の変分問題を扱う. Wasserstein 重心 (barycenter), 勾配流の変分定式化を論じる.
- 第10章：拡張と応用** 非平衡最適輸送 (unbalanced OT), Gromov–Wasserstein 距離, 部分最適輸送 (partial OT) など, 基本理論の拡張と具体的応用を扱う.

注意 1.3.1: 解説の3つの層

本書では, 以下の3つの枠組みを段階的に扱う:

1. **ヒストグラム** (確率ベクトル $\mathbf{a} \in \Sigma_n$): 最も基本的かつ計算に直結する設定であり, アルゴリズムの実装に必要な内容はこの枠組みで完結する.
2. **離散測度** ($\alpha = \sum_i a_i \delta_{x_i}$): 重みに加えて位置の自由度を持つ設定であり, 連続空間上の問題をより忠実にモデル化する.
3. **一般測度** (密度 $\rho_\alpha = d\alpha/dx$ を持つ測度など): 最も一般的な設定であり, 最適輸送理論の古典的な教科書で標準的に用いられる枠組みである.

第 2 章

理論的基礎

2.1 基本的な定義

本節では、距離空間、測度、確率測度、コスト関数などの基本概念を定義し、以降の議論で用いる記法を定める。

2.1.1 基本的な記法と概念

定義 2.1.1: 非負実数の空間

$\mathbb{R}_+ \stackrel{\text{def}}{=} \{x \in \mathbb{R} \mid x \geq 0\}$ と記す。 $\mathbb{R}_+^n$ は n 次元ベクトルで全成分が非負であるものの集合を表す。

定義 2.1.2: 凸集合

$\mathbb{R}^n$ の部分集合 S が凸 (convex) であるとは、任意の $x, y \in S$ と $t \in [0, 1]$ に対して $tx + (1-t)y \in S$ が成り立つことをいう。すなわち、 S の任意の 2 点を結ぶ線分が S に含まれる。

定義 2.1.3: 凸包

集合 $A \subset \mathbb{R}^n$ の凸包 (convex hull) とは、 A を含むすべての凸集合の共通部分をいい、 $\text{conv}(A)$ と表す：

$$\text{conv}(A) \stackrel{\text{def}}{=} \bigcap \{S \subset \mathbb{R}^n \mid A \subset S, S \text{ は凸}\}.$$

命題 2.1.4: 凸包の特徴づけ

集合 $A \subset \mathbb{R}^n$ に対して、

$$\text{conv}(A) = \left\{ \sum_{i=1}^k \lambda_i x_i \mid k \in \mathbb{N}, x_i \in A, \lambda_i \geq 0, \sum_{i=1}^k \lambda_i = 1 \right\}.$$

すなわち、凸包は A の有限個の点の凸結合全体に一致する。

定義 2.1.5: 端点

凸集合 S の点 $x \in S$ が端点 (extreme point) であるとは, $x = \frac{y+z}{2}$ かつ $y, z \in S$ ならば $x = y = z$ が成り立つことをいう. すなわち, x は S の他の 2 点の midpoint としては表せない.




図 2.1 凸集合・凸包・端点の例. 三角形 S は 3 点 x_1, x_2, x_3 の凸包であり, 凸集合である. 頂点 x_1, x_2, x_3 は S の端点であるが, 边上の点 p や内部の点は S 内の他の 2 点の midpoint として表せるため端点ではない.

定義 2.1.6: ほとんどいたるところ

測度 μ に関して, 性質 $P(x)$ がほとんどいたるところ (almost everywhere; a.e.) 成り立つとは, $P(x)$ が成り立たない点の集合 $\{x \mid \neg P(x)\}$ が μ -零集合 ($\mu(\{x \mid \neg P(x)\}) = 0$) であることをいう. μ がルベーグ測度の場合は単に「a.e.」と書く.

定義 2.1.7: 上極限と下極限

実数列 $(a_n)_{n \geq 1}$ に対して, 上極限 (limit superior) と下極限 (limit inferior) を

$$\limsup_{n \rightarrow \infty} a_n \stackrel{\text{def}}{=} \lim_{n \rightarrow \infty} \sup_{k \geq n} a_k, \quad \liminf_{n \rightarrow \infty} a_n \stackrel{\text{def}}{=} \lim_{n \rightarrow \infty} \inf_{k \geq n} a_k$$

で定義する. $\liminf a_n \leq \limsup a_n$ が常に成り立ち, 両者が一致するとき通常の極限 $\lim a_n$ が存在してその値に等しい.

定義 2.1.8: 下半連続

距離空間 (X, d) 上の関数 $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ が下半連続 (lower semicontinuous) であるとは, 任意の $x \in X$ と $x_n \rightarrow x$ なる任意の列に対して $f(x) \leq \liminf_{n \rightarrow \infty} f(x_n)$ が成り立つことをいう. 連続関数は下半連続であるが, 逆は成り立たない.




図 2.2 上極限と下極限. 黒点が数列 (a_n) の各項を表す. $\sup_{k \geq n} a_k$ は単調減少, $\inf_{k \geq n} a_k$ は単調増加であり, それぞれの極限が $\limsup a_n$, $\liminf a_n$ を与える.

2.1.2 距離空間

定義 2.1.9: 距離空間

集合 X と関数 $d: X \times X \rightarrow [0, \infty)$ の組 (X, d) が距離空間 (metric space) であるとは, 以下の 3 条件がすべての $x, y, z \in X$ に対して成り立つことをいう:

1. 同一性: $d(x, y) = 0 \iff x = y$.
2. 対称性: $d(x, y) = d(y, x)$.
3. 三角不等式: $d(x, z) \leq d(x, y) + d(y, z)$.

このとき d を X 上の距離関数 (metric) と呼ぶ.

例 2.1.10: ℓ^p 距離空間

実数 $p \geq 1$ に対して, $\mathbb{R}^n$ 上の ℓ^p 距離を

$$d_p(x, y) = \|x - y\|_p = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{1/p}$$

で定義する. 特に $p = 2$ のときユークリッド距離となる. 同一性と対称性は定義から直ちに従い, 三角不等式はミンコフスキーの不等式 (Minkowski's inequality) から成り立つ.

定義 2.1.11: コーシー列

距離空間 (X, d) における列 $(x_n)_{n \geq 1} \subset X$ がコーシー列 (Cauchy sequence) であるとは, 任意の $\varepsilon > 0$ に対してある $N \in \mathbb{N}$ が存在し, $n, m \geq N$ ならば $d(x_n, x_m) < \varepsilon$ が成り立つことをいう.

定義 2.1.12: 完備距離空間

距離空間 (X, d) が**完備** (complete) であるとは, X 上のすべてのコーシー列が X の点に収束すること
をいう. すなわち, $(x_n)_{n \geq 1}$ が X のコーシー列ならば, ある $x \in X$ が存在して $\lim_{n \rightarrow \infty} d(x_n, x) = 0$
となる.

注意 2.1.13: 完備でない距離空間の例

有理数全体 $\mathbb{Q}$ にユークリッド距離 $d(x, y) = |x - y|$ を入れた空間 $(\mathbb{Q}, d)$ は完備でない. 例えば, $\sqrt{2}$
の十進展開を途中で打ち切った有理数列 $x_1 = 1, x_2 = 1.4, x_3 = 1.41, x_4 = 1.414, \dots$ は $\mathbb{Q}$ 上の
コーシー列であるが, 極限 $\sqrt{2} \notin \mathbb{Q}$ であるから $\mathbb{Q}$ の中では収束しない. $\mathbb{R}$ は $\mathbb{Q}$ をこのような「穴」
がないように完備化した空間と見なせる.

定義 2.1.14: コンパクト集合

距離空間 (X, d) の部分集合 $K \subset X$ が**コンパクト** (compact) であるとは, K の任意の点列が K の
点に収束する部分列を持つことをいう.

例 2.1.15: $\mathbb{R}^d$ におけるコンパクト集合

$\mathbb{R}^d$ の部分集合がコンパクトであることは, その集合が**有界** (ある開球 $B(0, R)$ に含まれる) かつ**閉**
であることと同値である (Heine–Borel の定理). 例えば閉区間 $[a, b] \subset \mathbb{R}$ はコンパクトであるが, 開区
間 (a, b) は閉でないためコンパクトでなく, $\mathbb{R}$ 自身は有界でないためコンパクトでない.

定義 2.1.16: 可算集合

集合 A が**可算** (countable) であるとは, A から自然数全体 $\mathbb{N}$ への単射が存在することをいう. すな
わち, A の元を $a_1, a_2, a_3, \dots$ と番号付けできる. 有限集合は可算であり, $\mathbb{N}, \mathbb{Z}, \mathbb{Q}$ は可算である.
一方, $\mathbb{R}$ は可算でない (非可算である).

定義 2.1.17: 稠密部分集合と可分性

距離空間 (X, d) の部分集合 $D \subset X$ が**稠密** (dense) であるとは, 任意の $x \in X$ と任意の $\varepsilon > 0$ に対
して, ある $y \in D$ が存在して $d(x, y) < \varepsilon$ が成り立つことをいう. X が**可算**な稠密部分集合を持つと
き, X は**可分** (separable) であるという.

例 2.1.18: $\mathbb{R}$ の可分性

$\mathbb{Q}$ は $\mathbb{R}$ の稠密部分集合である. 実際, 任意の $x \in \mathbb{R}$ と任意の $\varepsilon > 0$ に対して, $\mathbb{R}$ のアルキメデスの
性質 (任意の $\varepsilon > 0$ に対して $n\varepsilon > 1$ となる $n \in \mathbb{N}$ が存在する) から $1/n < \varepsilon$ となる n が取れる.
すると $|x - m/n| < 1/n < \varepsilon$ を満たす整数 m が存在し, $q = m/n \in \mathbb{Q}$ が所望の有理数を与える. $\mathbb{Q}$
は可算集合であるから (定義 2.1.16), $\mathbb{R}$ は可分である.
一方, $\mathbb{Z}$ は $\mathbb{R}$ の稠密部分集合ではない. 例えば $x = 0.5, \varepsilon = 0.1$ に対して $|0.5 - n| < 0.1$ を満たす

$n \in \mathbb{Z}$ は存在しない.

定義 2.1.19: ポーランド空間

完備かつ可分な距離空間を**ポーランド空間** (Polish space) と呼ぶ.

例 2.1.20: $\mathbb{R}^d$ はポーランド空間

ユークリッド距離を備えた $\mathbb{R}^d$ はポーランド空間である. 完備性は解析学の基本定理であり, 可分性は $\mathbb{Q}^d$ が可算稠密部分集合であることから従う (例 2.1.18).

ポーランド空間を導入する理由は, この空間上で確率測度の集合に良いコンパクト性が成り立ち, 最適輸送問題の解の存在が保証されるためである. 詳細は確率測度を定義した後, 2.1.5 節で述べる.

2.1.3 可測空間とボレル集合族

測度を定義するためには, まず「測定可能な」集合の族を定める必要がある. その準備として, 距離空間における開集合と閉集合を定義する.

定義 2.1.21: 開球

距離空間 (X, d) において, 点 $x \in X$ と実数 $r > 0$ に対して, **開球** (open ball) を $B(x, r) \stackrel{\text{def}}{=} \{y \in X \mid d(x, y) < r\}$ で定義する.

定義 2.1.22: 開集合と閉集合

距離空間 (X, d) の部分集合 $U \subset X$ が**開集合** (open set) であるとは, 任意の $x \in U$ に対してある $r > 0$ が存在して $B(x, r) \subset U$ が成り立つことをいう. すなわち, U の各点のまわりに U に含まれる開球が取れる.

部分集合 $F \subset X$ が**閉集合** (closed set) であるとは, その補集合 $F^c = X \setminus F$ が開集合であることをいう. 同値な特徴づけとして, F が閉集合であることは, F の点列の極限が常に F に属すること (すなわち $x_n \in F, x_n \rightarrow x$ ならば $x \in F$) と同値である.

定義 2.1.23: σ -代数

集合 X の部分集合族 $\mathcal{B} \subset 2^X$ が **σ -代数** (σ -algebra) であるとは, 以下の 3 条件を満たすことをいう:

1. $X \in \mathcal{B}$.
2. $A \in \mathcal{B}$ ならば $A^c = X \setminus A \in \mathcal{B}$ (補集合で閉じている).
3. $A_1, A_2, \dots \in \mathcal{B}$ ならば $\bigcup_{k=1}^{\infty} A_k \in \mathcal{B}$ (可算合併で閉じている).

組 $(X, \mathcal{B})$ を**可測空間** (measurable space) と呼ぶ.

定義 2.1.24: ボレル σ -代数

距離空間 (X, d) に対して, X のすべての開集合を含む最小の σ -代数を**ボレル σ -代数** (Borel σ -algebra) と呼び, $\mathcal{B}(X)$ と記す. $\mathcal{B}(X)$ の元を**ボレル集合** (Borel set) と呼ぶ.

直感的には, ボレル σ -代数は「開集合と閉集合を基本ブロックとして, 可算回の集合演算で構成できるすべての集合」の族と理解できる. 確率や統計, 最適輸送で自然に現れる集合はほぼすべてボレル集合であり, 以降, 距離空間上の測度は常にボレル σ -代数に関して定義されるものとする.

2.1.4 測度と確率測度

定義 2.1.25: 測度

可測空間 $(X, \mathcal{B})$ 上の**測度** (measure) とは, 関数 $\mu: \mathcal{B} \rightarrow [0, \infty]$ であって, 以下を満たすものをいう:

1. $\mu(\emptyset) = 0$.
2. **可算加法的性**: 互いに素な列 $A_1, A_2, \dots \in \mathcal{B}$ に対して $\mu(\bigcup_{k=1}^{\infty} A_k) = \sum_{k=1}^{\infty} \mu(A_k)$.

定義 2.1.26: 確率測度

距離空間 X 上の**確率測度** (probability measure) とは, ボレル σ -代数 $\mathcal{B}(X)$ 上の測度 μ であって $\mu(X) = 1$ を満たすものをいう. X 上のすべての確率測度の集合を

$$\mathcal{M}_+^1(X) \stackrel{\text{def}}{=} \{\mu \in \mathcal{M}_+(X) \mid \mu(X) = 1\}$$

と記す. ここで $\mathcal{M}_+(X)$ は X 上のすべての非負ボレル測度の集合である.

注意 2.1.27: 測度の直感的理解

測度とは, 集合の各部分に「大きさ」や「質量」を割り当てる関数である. 確率測度は全体の質量が 1 に正規化されたものであり, 「確率分布」と同義に用いられる. 砂山の比喻を使えば, 確率測度は「各領域にどれだけの砂があるか」を記述する.

定義 2.1.28: 測度の台

距離空間 X 上の測度 μ の**台** (support) とは,

$$\text{supp}(\mu) \stackrel{\text{def}}{=} \{x \in X \mid x \text{ を含むすべての開集合 } U \text{ に対して } \mu(U) > 0\}$$

で定義される X の部分集合をいう.

$\text{supp}(\mu)$ は閉集合である. 実際, 補集合

$$\text{supp}(\mu)^c = \{x \in X \mid x \in U, \mu(U) = 0 \text{ なる開集合 } U \text{ が存在する}\}$$

が開集合であることを示せばよい. $x \in \text{supp}(\mu)^c$ ならば $x \in U$, $\mu(U) = 0$ なる開集合 U が存在する. 任意の $y \in U$ に対して, U は y の開近傍でもあり $\mu(U) = 0$ であるから, $y \in \text{supp}(\mu)^c$ となる. よって

$U \subset \text{supp}(\mu)^c$ であり, $\text{supp}(\mu)^c$ は開集合である.

定義 2.1.29: Dirac 測度

距離空間 X の点 $x \in X$ に対して, **Dirac 測度** (Dirac measure) δ_x を

$$\delta_x(A) \stackrel{\text{def}}{=} \begin{cases} 1 & x \in A, \\ 0 & x \notin A \end{cases} \quad (A \in \mathcal{B}(X))$$

で定義する. すなわち, δ_x は点 x に全質量を集中させた確率測度である. Dirac 測度に対する積分は $\int_X f(y) d\delta_x(y) = f(x)$ で与えられる.

2.1.5 確率測度のコンパクト性と Prokhorov の定理

最適輸送の Kantorovich 問題 (2.3 節で定式化) では, カップリング測度の集合の上でコストの下限を取る. この下限が実際に達成される (最適解が存在する) ためには, カップリングの集合がある種のコンパクト性を持つ必要がある.

ポーランド空間上では, 確率測度の集合のコンパクト性を「緊密性」という条件で特徴づけることができる. これが Prokhorov の定理であり, ポーランド空間を導入する根本的な理由である. 完備性がなければ極限測度が空間上の測度とならない可能性があり, 可分性がなければ以下の同値関係が成り立たない.

まず, 確率測度の列が「収束する」とはどういう意味かを定める. 直感的には, 測度 μ_n が μ に近づくとは, 任意の連続関数 f に対して f の μ_n による積分が f の μ による積分に近づくことをいう.

定義 2.1.30: 有界関数

距離空間 X 上の関数 $f: X \rightarrow \mathbb{R}$ が**有界** (bounded) であるとは, ある定数 $M \geq 0$ が存在して, すべての $x \in X$ に対して $|f(x)| \leq M$ が成り立つことをいう.

定義 2.1.31: 確率測度の弱収束

ポーランド空間 X 上の確率測度の列 $(\mu_n)_{n \geq 1}$ が確率測度 μ に**弱収束** (weakly converge) するとは, すべての有界連続関数 $f: X \rightarrow \mathbb{R}$ に対して

$$\lim_{n \rightarrow \infty} \int_X f d\mu_n = \int_X f d\mu$$

が成り立つことをいう.

弱収束に関する基本的な特徴づけとして, 以下の定理がある.

定理 2.1.32: Portmanteau の定理

ポーランド空間 X 上の確率測度の列 (μ_n) と確率測度 μ に対して, 以下は同値である:

1. μ_n が μ に弱収束する.


2. すべての閉集合 $F \subset X$ に対して $\limsup_{n \rightarrow \infty} \mu_n(F) \leq \mu(F)$.
3. すべての開集合 $U \subset X$ に対して $\liminf_{n \rightarrow \infty} \mu_n(U) \geq \mu(U)$.

注意 2.1.33


(2) と (3) は互いに補集合を取れば同値であることがわかる. Portmanteau の定理は, 弱収束が「閉集合上では測度が増えない」「開集合上では測度が減らない」という直感的な性質と同値であることを述べている.

弱収束する部分列を取るためには, 測度の質量が無遠慮に「逃げない」ことが必要である. 例えば, $\mathbb{R}$ 上の Dirac 測度の列 $\mu_n = \delta_n$ (点 n に全質量を集中させた測度) を考える.

緊密でない:



緊密:



上段は緊密でない場合: 各 $\mu_n = \delta_n$ の質量が際限なく移動し, どのコンパクト集合 K を取っても, 十分大きな n で $\mu_n(K) = 0$ となるため, 収束する部分列が存在しない. 下段は緊密な場合: すべての μ_n の質量が共通のコンパクト集合 K にほぼ収まっており, 収束する部分列を取ることができる. 緊密性はこのような状況を排除する条件である.

定義 2.1.34: 緊密性

ポーランド空間 X 上の確率測度の集合 $\Pi \subset \mathcal{M}_+^1(X)$ が**緊密** (tight) であるとは, 任意の $\varepsilon > 0$ に対してコンパクト集合 $K \subset X$ が存在し, すべての $\mu \in \Pi$ に対して $\mu(K) \geq 1 - \varepsilon$ が成り立つことをいう. すなわち, Π に属するすべての測度の質量が, 共通のコンパクト集合にほぼ集中している.

定義 2.1.35: 相対コンパクト性

距離空間の部分集合 S が**相対コンパクト** (relatively compact) であるとは, S の任意の列が収束する部分列を持つことをいう.

コンパクト集合の定義 (定義 2.1.14) では部分列の極限が元の集合に属することを要求するが, 相対コンパクトでは極限が S の外にあってもよい. $\mathbb{R}^d$ において「有界な列は収束部分列を持つ」(Bolzano–Weierstrass の定理) は, 有界集合が相対コンパクトであることの主張に他ならない.

定理 2.1.36: Prokhorov の定理

ポーランド空間 X 上の確率測度の集合 $\Pi \subset \mathcal{M}_+^1(X)$ に対して、以下は同値である：

1. Π は緊密である。
2. Π は弱収束に関して相対コンパクトである。

証明は Billingsley, *Convergence of Probability Measures* (1999) 等の測度論の教科書を参照されたい。直感的には、(1) $\Rightarrow$ (2) は対角線論法と Riesz の表現定理により弱収束する部分列を構成し、緊密性から極限が確率測度であることを示す。(2) $\Rightarrow$ (1) は対偶を取り、緊密でなければ弱収束する部分列が取れないことを示す。

2.1.6 確率単体

有限集合 $\{1, \dots, n\}$ 上の確率測度は、非負の重みベクトル $\mathbf{a} = (a_1, \dots, a_n)$ で $\sum_i a_i = 1$ を満たすものと同一視できる。このようなベクトルの全体が確率単体である。

定義 2.1.37: 確率単体

n 次元の**確率単体** (probability simplex) とは、 $\mathbb{R}^n$ の部分集合

$$\Sigma_n \stackrel{\text{def}}{=} \left\{ \mathbf{a} \in \mathbb{R}_+^n \mid \sum_{i=1}^n a_i = 1 \right\}$$


をいう。 Σ_n の元を**確率ベクトル** (probability vector) または**ヒストグラム** (histogram) と呼ぶ。

注意 2.1.38

Σ_n は $\mathbb{R}^n$ の凸かつコンパクトな部分集合である。その端点 (extreme points) は標準基底ベクトル $e_1, \dots, e_n$ であり、 Σ_n はこれらの凸包に等しい： $\Sigma_n = \text{conv}(e_1, \dots, e_n)$ 。

例 2.1.39: 低次元の確率単体

- $n = 2$ のとき、 $\Sigma_2 = \{(a_1, a_2) \in \mathbb{R}_+^2 \mid a_1 + a_2 = 1\}$ は $(1, 0)$ と $(0, 1)$ を結ぶ線分である。
- $n = 3$ のとき、 Σ_3 は $\mathbb{R}^3$ 内の三角形であり、頂点 $(1, 0, 0)$, $(0, 1, 0)$, $(0, 0, 1)$ を持つ。



2.1.7 離散測度

Dirac 測度（定義 2.1.29）を用いて，有限個の点に質量を持つ測度を構成できる．

注意 2.1.40

離散測度に対する積分を和に帰着させる際の基本は，Dirac 測度に対する積分の性質 $\int_X f(y) d\delta_x(y) = f(x)$ （定義 2.1.29）である．

定義 2.1.41: 離散測度

距離空間 X 上の**離散測度**（discrete measure）とは，有限個の点 $x_1, \dots, x_n \in X$ と非負の重み $a_1, \dots, a_n > 0$ に対して

$$\alpha = \sum_{i=1}^n a_i \delta_{x_i}$$

の形で表される測度をいう．さらに $\mathbf{a} = (a_1, \dots, a_n) \in \Sigma_n$ が成り立つとき， α は**離散確率測度**（discrete probability measure）と呼ばれる．

注意 2.1.42: ヒストグラムと離散測度の関係

ヒストグラム $\mathbf{a} \in \Sigma_n$ は，ビンの位置が固定された場合の確率ベクトルである．離散測度 $\alpha = \sum_i a_i \delta_{x_i}$ は，確率ベクトル $\mathbf{a}$ に加えて，各ビンの**位置** $(x_1, \dots, x_n)$ の情報も持つ．ヒストグラムは「重みのみ」を記述し，離散測度は「重みと位置の両方」を記述する．この区別は，特に異なる台を持つ離散測度を比較する際に本質的な意味を持つ．

例 2.1.43: 経験分布

データ点 $x_1, \dots, x_n \in X$ が何らかの確率分布から独立にサンプルされたとき、**経験分布** (empirical distribution)

$$\hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n \delta_{x_i}$$

は、データの分布を近似する離散確率測度である。大数の法則により、 $n \rightarrow \infty$ で $\hat{\mu}_n$ は真の分布に弱収束する。経験分布は最適輸送の応用（特に統計的推定）において重要な対象である。

2.1.8 測度の密度

離散測度に対する対極として、ルベグ測度に関して連続的な密度を持つ測度がある。

定義 2.1.44: ルベグ測度に関する密度

$X = \mathbb{R}^d$ 上の測度 α がルベグ測度に関して**密度** (density) ρ_α を持つとは、非負可測関数 $\rho_\alpha: \mathbb{R}^d \rightarrow [0, \infty)$ が存在して、すべてのボレル集合 $A \in \mathcal{B}(\mathbb{R}^d)$ に対して

$$\alpha(A) = \int_A \rho_\alpha(x) dx$$

が成り立つことをいう。ここで右辺はルベグ積分である。このとき $\rho_\alpha = \frac{d\alpha}{dx}$ と記す。 α が確率測度であるためには、 $\int_{\mathbb{R}^d} \rho_\alpha(x) dx = 1$ が必要十分である。

定義 2.1.45: ラドン–ニコディム導関数

より一般に、測度 α が測度 β に関して**絶対連続** (absolutely continuous; $\alpha \ll \beta$ と記す) であるとは、 $\beta(A) = 0$ ならば $\alpha(A) = 0$ が成り立つことをいう。このとき、ラドン–ニコディムの定理により、 β -可測関数 $\frac{d\alpha}{d\beta} \geq 0$ が β -a.e. に一意的に存在して、

$$\alpha(A) = \int_A \frac{d\alpha}{d\beta}(x) d\beta(x) \quad (\forall A \in \mathcal{B}(X))$$

が成り立つ。この関数 $\frac{d\alpha}{d\beta}$ を α の β に関する**ラドン–ニコディム導関数** (Radon–Nikodym derivative) または**相対密度**と呼ぶ。

注意 2.1.46: 測度の3つの類型

最適輸送の理論では、主に以下の3種類の測度を扱う：

1. **ヒストグラム**： $\mathbf{a} \in \Sigma_n$ (有限次元の確率ベクトル)。ピンの位置は固定されており、最も単純な設定である。
2. **離散測度**： $\alpha = \sum_i a_i \delta_{x_i}$ (有限個の点に台を持つ測度)。重みと位置の両方が自由度を持つ。
3. **連続測度**： $d\alpha(x) = \rho_\alpha(x) dx$ (ルベグ測度に関して密度を持つ測度)。最も一般的であるが、

計算上は最も扱いが難しい.

本書では, 主にヒストグラムと離散測度を扱い, 必要に応じて連続測度への拡張にも触れる.

2.1.9 コスト関数

最適輸送の目的関数を定めるのがコスト関数である.

定義 2.1.47: コスト関数

空間 $\mathcal{X}$ と $\mathcal{Y}$ に対して, **コスト関数** (cost function) とは, 可測関数

$$c: \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}_+ \cup \{+\infty\}$$

をいう. $c(x, y)$ は, 点 $x \in \mathcal{X}$ から点 $y \in \mathcal{Y}$ へ単位質量を輸送するコストを表す.

例 2.1.48: 典型的なコスト関数

(X, d) を距離空間とし, $\mathcal{X} = \mathcal{Y} = X$ とする.

1. **距離コスト**: $c(x, y) = d(x, y)$. p -Wasserstein 距離 ($p = 1$) に対応する.
2. **二乗距離コスト**: $c(x, y) = d(x, y)^2$. 最もよく研究されているケースであり, Brenier の定理の仮定となる. 特に $X = \mathbb{R}^d$ では $c(x, y) = \|x - y\|_2^2$ である.
3. **p 乗距離コスト**: $c(x, y) = d(x, y)^p$ ($p \geq 1$). p -Wasserstein 距離を導く.
4. **離散コスト行列**: 点集合 $x_1, \dots, x_n \in \mathcal{X}$ と $y_1, \dots, y_m \in \mathcal{Y}$ が固定されているとき, $n \times m$ 行列 $\mathbf{C}$ を $C_{i,j} = c(x_i, y_j)$ で定義する. これを**コスト行列** (cost matrix) と呼ぶ.

2.2 最適割当問題と Monge 問題

2.2.1 最適割当問題

Monge 問題を定式化する前に, その特殊な場合である最適割当問題を導入する.

定義 2.2.1: 置換

有限集合 $\llbracket n \rrbracket = \{1, \dots, n\}$ 上の**置換** (permutation) とは, $\llbracket n \rrbracket$ から $\llbracket n \rrbracket$ への全単射 $\sigma: \llbracket n \rrbracket \rightarrow \llbracket n \rrbracket$ をいう. $\llbracket n \rrbracket$ 上のすべての置換の集合を $\text{Perm}(n)$ と記す. $\text{Perm}(n)$ の元の個数は $n!$ である.

定義 2.2.2: 置換行列

置換 $\sigma \in \text{Perm}(n)$ に対して, 置換行列 $\mathbf{P}_\sigma \in \{0, 1\}^{n \times n}$ を

$$(\mathbf{P}_\sigma)_{i,j} = \begin{cases} 1 & j = \sigma(i), \\ 0 & j \neq \sigma(i) \end{cases}$$

で定義する. 置換行列は各行・各列にちょうど 1 つの 1 を持つ行列であり, $\mathbf{P}_\sigma \mathbf{1}_n = \mathbf{1}_n$ かつ $\mathbf{P}_\sigma^\top \mathbf{1}_n = \mathbf{1}_n$ を満たす.

設定 2.2.3: 最適割当問題

コスト行列 $\mathbf{C} \in \mathbb{R}^{n \times n}$ が与えられたとき, 最適割当問題 (optimal assignment problem) とは,

$$\min_{\sigma \in \text{Perm}(n)} \frac{1}{n} \sum_{i=1}^n C_{i, \sigma(i)}$$

を求める問題である. これは n 個のソースと n 個のターゲットの間に 1 対 1 対応を見つけ, 総コストを最小化する問題である.

注意 2.2.4

置換の全探索は $n!$ 通りの列挙を要し, $n = 70$ でも $n! > 10^{100}$ となるため実用上不可能である. 効率的な解法 (オークションアルゴリズムやハンガリアン法など) は第 3 章で扱う.

最適割当問題は, ソースとターゲットの個数が等しく ($n = m$), すべての重みが均一 ($a_i = b_j = 1/n$) という特殊な設定であった. 次に扱う Monge 問題は, 個数が異なる場合 ($n \neq m$) や重みが不均一な場合を含む一般化である. 割当問題では写像が全単射 (置換) であったのに対し, Monge 問題では複数のソース点と同じターゲット点に送られることも許される.

2.2.2 Monge 問題

Monge (1781) は, ある分布の質量を別の分布へ写像によって移すとき, 総コストを最小にする問題を定式化した. この問題を正確に述べるためには, 写像による測度の「移動」を定義する必要がある.

定義 2.2.5: 可測写像

可測空間 $(X, \mathcal{B}(X))$ と $(Y, \mathcal{B}(Y))$ の間の写像 $T: X \rightarrow Y$ が可測 (measurable) であるとは, 任意の $B \in \mathcal{B}(Y)$ に対して $T^{-1}(B) \in \mathcal{B}(X)$ が成り立つことをいう.

命題 2.2.6: 連続写像は可測

距離空間 (X, d_X) と (Y, d_Y) の間の連続写像 $T: X \rightarrow Y$ は, ボレル σ -代数に関して可測である.

Proof. $U \subset Y$ を開集合とする. T は連続であるから, $T^{-1}(U)$ は X の開集合であり, $T^{-1}(U) \in \mathcal{B}(X)$ が成り立つ. $\mathcal{B}(Y)$ は Y のすべての開集合を含む最小の σ -代数であるから, $\{B \in \mathcal{B}(Y) \mid T^{-1}(B) \in \mathcal{B}(X)\}$ が σ -代数であること (T^{-1} が合併・補集合と可換であることから従う) と, この σ -代数がすべての開集合を含むことを合わせると, $\mathcal{B}(Y) \subset \{B \in \mathcal{B}(Y) \mid T^{-1}(B) \in \mathcal{B}(X)\}$ が得られる. $\square$

定義 2.2.7: 押し出し (push-forward)

$(X, \mathcal{B}(X))$ と $(Y, \mathcal{B}(Y))$ を可測空間とし, $T: X \rightarrow Y$ を可測写像とする. 測度 $\alpha \in \mathcal{M}_+(X)$ の T による押し出し $T_{\#}\alpha \in \mathcal{M}_+(Y)$ を

$$(T_{\#}\alpha)(B) \stackrel{\text{def}}{=} \alpha(T^{-1}(B)) \quad (\forall B \in \mathcal{B}(Y))$$

で定義する. ここで $T^{-1}(B) = \{x \in X \mid T(x) \in B\}$ は B の逆像である.

注意 2.2.8

押し出しの定義を積分の言葉で述べると, すべての可測関数 $h: Y \rightarrow \mathbb{R}$ に対して

$$\int_Y h(y) d(T_{\#}\alpha)(y) = \int_X h(T(x)) d\alpha(x)$$

が成り立つ. 離散測度 $\alpha = \sum_i a_i \delta_{x_i}$ に対しては,

$$T_{\#}\alpha = \sum_{i=1}^n a_i \delta_{T(x_i)}$$

となる. すなわち, 押し出しは各点 x_i の位置を $T(x_i)$ に移し, 重み a_i は保存する操作である.

以上を用いて, Monge 問題を定式化する.

設定 2.2.9: Monge 問題

ソース空間 $\mathcal{X}$ 上の確率測度 $\alpha \in \mathcal{M}_+^1(\mathcal{X})$, ターゲット空間 $\mathcal{Y}$ 上の確率測度 $\beta \in \mathcal{M}_+^1(\mathcal{Y})$, およびコスト関数 $c: \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}_+$ が与えられたとき, **Monge 問題**とは次の最適化問題をいう:

$$\inf_{\substack{T: \mathcal{X} \rightarrow \mathcal{Y} \\ T_{\#}\alpha = \beta}} \int_{\mathcal{X}} c(x, T(x)) d\alpha(x).$$

ここで最適化は, $T_{\#}\alpha = \beta$ を満たすすべての可測写像 T にわたって行う. 条件 $T_{\#}\alpha = \beta$ は, 写像 T がソースの質量分布をターゲットの質量分布に正確に移すことを要求する.

Monge 問題には, 以下の本質的な困難がある.


注意 2.2.10: Monge 問題の困難

1. **非凸性**: 実行可能集合 $\{T: T_{\#}\alpha = \beta\}$ は一般に**凸でない**. すなわち, 2 つの実行可能な写像 T_1, T_2 に対して, その凸結合 $(1-t)T_1 + tT_2$ は一般に実行可能でない (押し出し条件は写像に関して非線形だからである). このため, 標準的な凸最適化の手法が直接は適用できない.
2. **解の非存在**: 以下の例 2.2.11 に示すように, 実行可能な写像 T が**存在しない**場合がある. 特に, ソース測度がターゲット測度より「粗い」(少数の点に質量が集中している) 場合に, 質量を分割できないという制約が障害となる.

例 2.2.11: Monge 写像が存在しない場合

$\mathcal{X} = \mathcal{Y} = \mathbb{R}$ 上で, ソース測度 $\alpha = \delta_0$ (原点に全質量を集中), ターゲット測度 $\beta = \frac{1}{2}\delta_{-1} + \frac{1}{2}\delta_1$ (-1 と 1 に半分ずつ質量を配置) を考える.

$T_{\#}\alpha = \beta$ を満たす写像 $T: \mathbb{R} \rightarrow \mathbb{R}$ が存在すると仮定する. $\alpha = \delta_0$ であるから, $T_{\#}\delta_0 = \delta_{T(0)}$ となる. しかし $\delta_{T(0)}$ は 1 点に集中した測度であり, $\beta = \frac{1}{2}\delta_{-1} + \frac{1}{2}\delta_1$ は 2 点に質量を持つ. よって $\delta_{T(0)} \neq \beta$ であり, 矛盾する.



この例は, Monge の定式化では質量の「分割」が許されないために解が存在しないことを端的に示している. Kantorovich の緩和 (次節) は, まさにこの困難を解消するものである.

2.3 Kantorovich 緩和の概要

Kantorovich (1942) の革命的なアイデアは, Monge の決定論的な輸送写像 T を**確率的な輸送計画**に置き換えることである. すなわち, 各点 x の質量を **1 つの行き先に集中させる**代わりに, **複数の行き先に分割して送る**ことを許す. この確率的な輸送計画は, $\mathcal{X} \times \mathcal{Y}$ 上の結合測度 (カップリング) として定式化される.

定義 2.3.1: カップリング

確率測度 $\alpha \in \mathcal{M}_+^1(\mathcal{X})$ と $\beta \in \mathcal{M}_+^1(\mathcal{Y})$ に対して, α と β の**カップリング** (coupling) の集合を

$$\mathcal{U}(\alpha, \beta) \stackrel{\text{def}}{=} \{ \pi \in \mathcal{M}_+^1(\mathcal{X} \times \mathcal{Y}) \mid (P_{\mathcal{X}})_{\#}\pi = \alpha, (P_{\mathcal{Y}})_{\#}\pi = \beta \}$$

で定義する. ここで $P_{\mathcal{X}}(x, y) = x$, $P_{\mathcal{Y}}(x, y) = y$ はそれぞれ第 1 成分・第 2 成分への射影である. すなわち, π の**周辺分布** (marginals) がそれぞれ α, β に一致することを要求する.

注意 2.3.2: 周辺分布の条件

周辺分布の条件を積分で書くと、任意の可測関数 φ, ψ に対して

$$\begin{aligned}\int_{\mathcal{X} \times \mathcal{Y}} \varphi(x) d\pi(x, y) &= \int_{\mathcal{X}} \varphi(x) d\alpha(x), \\ \int_{\mathcal{X} \times \mathcal{Y}} \psi(y) d\pi(x, y) &= \int_{\mathcal{Y}} \psi(y) d\beta(y)\end{aligned}$$

が成り立つことと同値である。直感的には、 $\pi(A \times \mathcal{Y}) = \alpha(A)$ ($A \subset \mathcal{X}$) および $\pi(\mathcal{X} \times B) = \beta(B)$ ($B \subset \mathcal{Y}$) が要求されている。

注意 2.3.3: 離散版カップリング

ヒストグラム $\mathbf{a} \in \Sigma_n$, $\mathbf{b} \in \Sigma_m$ に対する離散的なカップリングは $n \times m$ の非負行列 $\mathbf{P}$ で表され、

$$\mathbf{U}(\mathbf{a}, \mathbf{b}) \stackrel{\text{def}}{=} \{\mathbf{P} \in \mathbb{R}_+^{n \times m} \mid \mathbf{P}\mathbf{1}_m = \mathbf{a}, \mathbf{P}^\top \mathbf{1}_n = \mathbf{b}\}$$

で定義される。ここで $\mathbf{1}_k$ は成分がすべて 1 の k 次元ベクトルである。 $P_{i,j}$ は「ソースのビン i からターゲットのビン j へ輸送される質量」を表す。行和の条件 $\mathbf{P}\mathbf{1}_m = \mathbf{a}$ は供給制約、列和の条件 $\mathbf{P}^\top \mathbf{1}_n = \mathbf{b}$ は需要制約に対応する。

定義 2.3.4: Birkhoff 多面体

$n = m$ かつ $\mathbf{a} = \mathbf{b} = \mathbf{1}_n/n$ (均一重み) のとき、 $\mathbf{U}(\mathbf{1}_n/n, \mathbf{1}_n/n)$ を **Birkhoff 多面体** (Birkhoff polytope) と呼ぶ。これは二重確率行列 (doubly stochastic matrix; すべての行和・列和が $1/n$ の非負行列) の集合に等しい。

定理 2.3.5: Birkhoff–von Neumann の定理

Birkhoff 多面体の端点 (extreme point) は $\frac{1}{n}\mathbf{P}_\sigma$ ($\sigma \in \text{Perm}(n)$) の形の置換行列に限る。すなわち、任意の二重確率行列は置換行列の凸結合として表される。

注意 2.3.6

線形計画問題の最適解は多面体の端点で達成されるから、均一重みの場合の Kantorovich 問題は置換行列で最適解を持つ。これは最適割当問題 (設定 2.2.3) の最適値と一致し、Kantorovich 緩和が割当問題のタイトな緩和であることを意味する。

注意 2.3.7: カップリングの存在

$\mathbf{U}(\alpha, \beta)$ は常に空でない。実際、積測度 (product measure) $\alpha \otimes \beta$ はカップリングの一つである：

$$(\alpha \otimes \beta)(A \times B) = \alpha(A) \cdot \beta(B) \quad (\forall A \in \mathcal{B}(\mathcal{X}), B \in \mathcal{B}(\mathcal{Y})).$$

これは「ソースとターゲットを独立に結合する」最も情報を持たないカップリングであり、一般に最適ではないが、実行可能性を保証する。離散版では $\mathbf{P} = \mathbf{a}\mathbf{b}^\top$ (外積) が対応する。

以上を用いて, Kantorovich 問題を定式化する.

設定 2.3.8: Kantorovich 問題

確率測度 $\alpha \in \mathcal{M}_+^1(\mathcal{X})$, $\beta \in \mathcal{M}_+^1(\mathcal{Y})$, およびコスト関数 $c: \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}_+$ に対して, **Kantorovich 問題**とは次の最適化問題をいう:

$$\mathcal{L}_c(\alpha, \beta) \stackrel{\text{def}}{=} \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\pi(x, y).$$

ヒストグラム $\mathbf{a} \in \Sigma_n$, $\mathbf{b} \in \Sigma_m$ とコスト行列 $\mathbf{C} \in \mathbb{R}_+^{n \times m}$ に対する離散版は

$$L_{\mathbf{C}}(\mathbf{a}, \mathbf{b}) \stackrel{\text{def}}{=} \min_{\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})} \sum_{i,j} C_{i,j} P_{i,j} = \min_{\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})} \langle \mathbf{C}, \mathbf{P} \rangle$$

で与えられる. ここで $\langle \mathbf{C}, \mathbf{P} \rangle = \text{tr}(\mathbf{C}^\top \mathbf{P})$ はフロベニウス内積である.

注意 2.3.9: 確率論的解釈

Kantorovich 問題は確率論の言葉で次のように述べられる. 確率変数 $X \sim \alpha$, $Y \sim \beta$ の同時分布 (X, Y) のうち, 周辺分布がそれぞれ α, β に一致するものを考えて,

$$\mathcal{L}_c(\alpha, \beta) = \inf_{\substack{(X,Y) \\ X \sim \alpha, Y \sim \beta}} \mathbb{E}[c(X, Y)].$$

すなわち, 周辺分布を固定したもとの輸送コストの期待値を最小化する問題である. カップリング π は同時分布に対応し, 周辺分布の制約は $X \sim \alpha$, $Y \sim \beta$ に対応する.

Kantorovich 緩和が Monge の定式化より優れている理由を整理する.

注意 2.3.10: Kantorovich 緩和の利点

1. **凸性**: $\mathcal{U}(\alpha, \beta)$ は凸集合である (2つのカップリングの凸結合は再びカップリング). 目的関数 $\pi \mapsto \int c d\pi$ は π に関して線形であるから, Kantorovich 問題は**凸最適化問題**である.
2. **線形計画**: 離散版は有限次元の**線形計画問題** (LP) であり, 単体法や内点法などの効率的なアルゴリズムで解ける.
3. **解の存在**: $\mathcal{X}, \mathcal{Y}$ がポーランド空間かつ c が下半連続ならば, $\mathcal{U}(\alpha, \beta)$ は緊密かつ弱位相で閉であることが示される. したがって Prokhorov の定理 (定理 2.1.36) から $\mathcal{U}(\alpha, \beta)$ は弱収束に関してコンパクトとなり, 目的関数は弱収束に関して下半連続であるから, 最適なカップリング π^* が**常に存在**する. 離散版でも, $\mathbf{U}(\mathbf{a}, \mathbf{b})$ はコンパクト凸集合であるから, 最適な輸送計画は常に存在する.

Monge 問題と Kantorovich 問題の関係を明確にしておく.

命題 2.3.11: Monge 問題との関係

$T_{\#}\alpha = \beta$ を満たす可測写像 $T: \mathcal{X} \rightarrow \mathcal{Y}$ に対して,

$$\pi_T \stackrel{\text{def}}{=} (\text{Id}, T)_{\#}\alpha$$

で定義される測度 $\pi_T \in \mathcal{M}_+^1(\mathcal{X} \times \mathcal{Y})$ は $\mathcal{U}(\alpha, \beta)$ の元であり,

$$\int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\pi_T(x, y) = \int_{\mathcal{X}} c(x, T(x)) d\alpha(x)$$

が成り立つ. ここで $(\text{Id}, T)(x) = (x, T(x))$ である. したがって,

$$\mathcal{L}_c(\alpha, \beta) \leq \inf_{\substack{T: \mathcal{X} \rightarrow \mathcal{Y} \\ T_{\#}\alpha = \beta}} \int_{\mathcal{X}} c(x, T(x)) d\alpha(x).$$

すなわち, Kantorovich 問題は Monge 問題の緩和である.

Proof. $\pi_T = (\text{Id}, T)_{\#}\alpha$ の周辺分布を確認する. 任意のボレル集合 $A \subset \mathcal{X}$ に対して,

$$\pi_T(A \times \mathcal{Y}) = \alpha(\{x \in \mathcal{X} \mid (x, T(x)) \in A \times \mathcal{Y}\}) = \alpha(A),$$

また任意のボレル集合 $B \subset \mathcal{Y}$ に対して,

$$\pi_T(\mathcal{X} \times B) = \alpha(\{x \in \mathcal{X} \mid T(x) \in B\}) = \alpha(T^{-1}(B)) = (T_{\#}\alpha)(B) = \beta(B).$$

よって $\pi_T \in \mathcal{U}(\alpha, \beta)$ である.

コストの等式は, 押し出しの定義から直ちに従う:


$$\int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\pi_T(x, y) = \int_{\mathcal{X}} c(x, T(x)) d\alpha(x).$$

Kantorovich 問題は $\mathcal{U}(\alpha, \beta)$ 全体にわたる下限であるから, 特に π_T に対するコスト以下であり, 不等式が得られる. $\square$


注意 2.3.12

上の命題は, Monge 写像 T による輸送がカップリングの特殊な場合—すなわち, π が T のグラフ $\{(x, T(x))\}$ 上に集中しているもの—であることを示している. Kantorovich の緩和は, このグラフ上への集中の要求を外すことで, より広い実行可能領域を得ている.

Monge 写像



Kantorovich カップリング



左の Monge 写像では各点 x_i は 1 つの行き先にのみ送られるが、右の Kantorovich カップリングでは x_2 の質量が y_1 と y_2 に分割されている。

2.4 Wasserstein 距離の概要

コスト関数が距離から導かれる場合、最適輸送コストは確率測度の空間に自然な距離構造を導入する。これが Wasserstein 距離である。

定義 2.4.1: p -Wasserstein 距離

(X, d) を距離空間とし、 $p \geq 1$ とする。確率測度 $\alpha, \beta \in \mathcal{M}_+^1(X)$ に対して、 p -Wasserstein 距離 (p -Wasserstein distance) を

$$\mathcal{W}_p(\alpha, \beta) \stackrel{\text{def}}{=} \left(\inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int_{X \times X} d(x, y)^p d\pi(x, y) \right)^{1/p}$$

で定義する。すなわち、 $\mathcal{W}_p(\alpha, \beta) = \mathcal{L}_{d^p}(\alpha, \beta)^{1/p}$ である。

ヒストグラム $\mathbf{a}, \mathbf{b}$ と距離行列 $\mathbf{D}$ ($D_{i,j} = d(x_i, y_j)$) に対する離散版は

$$\mathcal{W}_p(\mathbf{a}, \mathbf{b}) = \mathcal{L}_{\mathbf{D}^{\circ p}}(\mathbf{a}, \mathbf{b})^{1/p}$$

で与えられる。ここで $\mathbf{D}^{\circ p}$ は $D_{i,j}^p$ を成分とする行列である。

命題 2.4.2: $\mathcal{W}_p$ は距離である

(X, d) を距離空間、 $p \geq 1$ とする。有限 p 次モーメントを持つ確率測度の空間

$$\mathcal{M}_+^{1,p}(X) \stackrel{\text{def}}{=} \left\{ \alpha \in \mathcal{M}_+^1(X) \mid \int_X d(x, x_0)^p d\alpha(x) < \infty \right\}$$

(ここで $x_0 \in X$ は任意の固定点) において、 $\mathcal{W}_p$ は距離の公理を満たす：

1. $\mathcal{W}_p(\alpha, \beta) = 0 \iff \alpha = \beta$.
2. $\mathcal{W}_p(\alpha, \beta) = \mathcal{W}_p(\beta, \alpha)$.
3. $\mathcal{W}_p(\alpha, \gamma) \leq \mathcal{W}_p(\alpha, \beta) + \mathcal{W}_p(\beta, \gamma)$.

三角不等式の証明には以下の補題が必要である。

命題 2.4.3: 糊付け補題

ポーランド空間 X, Y, Z 上の確率測度に対して、 $\pi_1 \in \mathcal{U}(\alpha, \beta)$ ($X \times Y$ 上) と $\pi_2 \in \mathcal{U}(\beta, \gamma)$ ($Y \times Z$ 上) が与えられたとき、 $X \times Y \times Z$ 上の確率測度 μ であって、 $(X \times Y)$ への周辺分布が π_1 に、 $(Y \times Z)$ への周辺分布が π_2 に一致するものが存在する。

Proof. π_1 の Y 上の条件付き分布を $\pi_1(\cdot | y)$, π_2 の Y 上の条件付き分布を $\pi_2(\cdot | y)$ と書くと, μ を

$$d\mu(x, y, z) = d\pi_1(x | y) d\beta(y) d\pi_2(z | y)$$

で定義すればよい. $(X \times Y)$ への周辺は $d\pi_1(x | y) d\beta(y) = d\pi_1(x, y)$, $(Y \times Z)$ への周辺は $d\beta(y) d\pi_2(z | y) = d\pi_2(y, z)$ となり, 所望の性質を持つ. $\square$

命題 2.4.2 の証明. (1) 同一性: $\alpha = \beta$ ならば $\pi = (\text{Id}, \text{Id})_{\#} \alpha$ (対角線上に集中したカップリング) が $\mathcal{U}(\alpha, \alpha)$ の元であり, $\int d(x, y)^p d\pi = \int d(x, x)^p d\alpha = 0$ であるから $\mathcal{W}_p(\alpha, \alpha) = 0$. 逆に $\mathcal{W}_p(\alpha, \beta) = 0$ ならば, 最適カップリング π^* に対して $\int d(x, y)^p d\pi^* = 0$ であるから, π^* は $\{(x, y) | x = y\}$ 上に集中し, $\alpha = (P_X)_{\#} \pi^* = (P_Y)_{\#} \pi^* = \beta$ が従う.

(2) 対称性: 写像 $S(x, y) = (y, x)$ による押し出しは $\mathcal{U}(\alpha, \beta)$ と $\mathcal{U}(\beta, \alpha)$ の間の全単射を与え, $d(x, y) = d(y, x)$ から $\mathcal{W}_p(\alpha, \beta) = \mathcal{W}_p(\beta, \alpha)$ が従う.

(3) 三角不等式: $\pi_1 \in \mathcal{U}(\alpha, \beta)$ と $\pi_2 \in \mathcal{U}(\beta, \gamma)$ をそれぞれ $\mathcal{W}_p(\alpha, \beta)$ と $\mathcal{W}_p(\beta, \gamma)$ の最適カップリングとする. 糊付け補題 (gluing lemma) により, $\mathcal{X} \times \mathcal{Y} \times \mathcal{X}$ 上の測度 μ であって, $(\mathcal{X} \times \mathcal{Y})$ への周辺が π_1 に, $(\mathcal{Y} \times \mathcal{X})$ への周辺が π_2 に一致するものが存在する. $(P_1, P_3)_{\#} \mu \in \mathcal{U}(\alpha, \gamma)$ (P_1, P_3 はそれぞれ第 1・第 3 成分への射影) を α と γ のカップリングとして用いると, ミンコフスキーの不等式から

$$\begin{aligned} \mathcal{W}_p(\alpha, \gamma) &\leq \left(\int d(x, z)^p d\mu(x, y, z) \right)^{1/p} \\ &\leq \left(\int d(x, y)^p d\mu(x, y, z) \right)^{1/p} + \left(\int d(y, z)^p d\mu(x, y, z) \right)^{1/p} \\ &= \mathcal{W}_p(\alpha, \beta) + \mathcal{W}_p(\beta, \gamma) \end{aligned}$$

が得られる. 2 行目では距離の三角不等式 $d(x, z) \leq d(x, y) + d(y, z)$ と L^p 空間のミンコフスキーの不等式を用いた. $\square$

注意 2.4.4: Wasserstein 距離の意義

Wasserstein 距離は, 確率測度の空間に**基底空間の幾何学を反映した距離**を与える. この性質は, **KL ダイバージェンス** (Kullback–Leibler divergence)

$$\text{KL}(\alpha \| \beta) \stackrel{\text{def}}{=} \int \log \frac{d\alpha}{d\beta} d\alpha \quad (\alpha \ll \beta \text{ のとき; そうでなければ } +\infty)$$

など他の分布間の乖離度とは対照的である. ここで $\frac{d\alpha}{d\beta}$ はラドン–ニコディム導関数 (定義 2.1.45) である. KL ダイバージェンスは基底空間の距離構造を一切考慮しないが, Wasserstein 距離は点間の距離 $d(x, y)$ を通じてこれを取り込む.

また, KL ダイバージェンスは台が重ならない分布間では $+\infty$ となるが, Wasserstein 距離は台が異なる場合でも有限の値を取り得る. このため, Wasserstein 距離は機械学習 (特に生成モデル) において分布間の類似度を測る指標として広く用いられている.

例 2.4.5: Dirac 測度間の Wasserstein 距離

2 つの Dirac 測度 δ_x と δ_y ($x, y \in X$) に対して, 唯一のカップリングは $\pi = \delta_{(x,y)}$ であるから,

$$\mathcal{W}_p(\delta_x, \delta_y) = \left(\int_{X \times X} d(u, v)^p d\delta_{(x,y)}(u, v) \right)^{1/p} = d(x, y).$$

すなわち, Wasserstein 距離は点間の距離を確率測度の距離に自然に持ち上げる.

命題 2.4.6: Wasserstein 距離と弱収束

(X, d) をポーランド空間, $p \geq 1$ とする. 確率測度の列 $(\alpha_k)_{k \geq 1} \subset \mathcal{M}_+^{1,p}(X)$ と $\alpha \in \mathcal{M}_+^{1,p}(X)$ に対して, 以下は同値である:

1. $\mathcal{W}_p(\alpha_k, \alpha) \rightarrow 0$.
2. α_k が α に弱収束し, かつ p 次モーメントが収束する: $\int_X d(x, x_0)^p d\alpha_k(x) \rightarrow \int_X d(x, x_0)^p d\alpha(x)$.

特に (X, d) がコンパクトならば, $\mathcal{W}_p$ による収束と弱収束は同値である.

注意 2.4.7: $\mathcal{W}_\infty$ 距離

$p \rightarrow \infty$ の極限として, $\mathcal{W}_\infty$ 距離を

$$\mathcal{W}_\infty(\alpha, \beta) \stackrel{\text{def}}{=} \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \sup_{(x, y) \in \text{supp}(\pi)} d(x, y)$$

で定義する (より正確には π に関する本質的上限を取る). $\mathcal{W}_\infty$ は台の間の Hausdorff 距離と関連するが, 有限 p の場合と異なり非凸最適化問題となる.

注意 2.4.8: 平行移動の分解

$X = \mathbb{R}^d$, $c(x, y) = \|x - y\|_2^2$ のとき, 確率測度 α の平均を $\bar{x}_\alpha \stackrel{\text{def}}{=} \int_{\mathbb{R}^d} x d\alpha(x)$ と定め, $\tilde{\alpha}$ を α を平均が原点になるよう平行移動した測度とする. すなわち, $\tilde{\alpha} \stackrel{\text{def}}{=} (x \mapsto x - \bar{x}_\alpha)_\# \alpha$ とすると,

$$\mathcal{W}_2(\alpha, \beta)^2 = \mathcal{W}_2(\tilde{\alpha}, \tilde{\beta})^2 + \|\bar{x}_\alpha - \bar{x}_\beta\|_2^2$$

が成り立つ. Wasserstein 距離は「平均の差」と「平均を揃えた後の分布形状の差」に直交分解される. この分解はガウス分布の場合 (定理 2.6.10) の平均項と Bures 距離項への分解の一般化である.

2.5 双対問題

Kantorovich 問題は線形計画問題であるから, 線形計画の双対理論が適用できる. 双対問題は最適輸送の理論的理解と計算手法の両面で重要な役割を果たす. ここではまず必要な最適化の概念を導入し, その後で双対問題を定式化する.

2.5.1 線形計画と双対理論

定義 2.5.1: 線形計画問題

ベクトル $\mathbf{c} \in \mathbb{R}^N$, 行列 $\mathbf{A} \in \mathbb{R}^{M \times N}$, ベクトル $\mathbf{b} \in \mathbb{R}^M$ に対して, **線形計画問題** (linear program; LP) とは

$$\min_{\mathbf{x} \in \mathbb{R}^N} \{ \langle \mathbf{c}, \mathbf{x} \rangle \mid \mathbf{Ax} = \mathbf{b}, \mathbf{x} \geq 0 \}$$

の形の最適化問題をいう. 目的関数 $\langle \mathbf{c}, \mathbf{x} \rangle$ と制約がいずれも $\mathbf{x}$ に関して線形である.

注意 2.5.2: Kantorovich 問題は線形計画である

離散版の Kantorovich 問題 $\min_{\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})} \langle \mathbf{C}, \mathbf{P} \rangle$ は, 行列 $\mathbf{P}$ をベクトルに並べ直すことで上の形式の線形計画に帰着される. 制約 $\mathbf{P}\mathbf{1}_m = \mathbf{a}$, $\mathbf{P}^\top \mathbf{1}_n = \mathbf{b}$, $\mathbf{P} \geq 0$ はいずれも線形である.

定義 2.5.3: ラグランジュ関数

等式制約付き最適化問題 $\min_{\mathbf{x}} \{ f(\mathbf{x}) \mid h_k(\mathbf{x}) = 0, k = 1, \dots, M \}$ に対して, **ラグランジュ関数** (Lagrangian) を

$$L(\mathbf{x}, \boldsymbol{\lambda}) \stackrel{\text{def}}{=} f(\mathbf{x}) + \sum_{k=1}^M \lambda_k h_k(\mathbf{x})$$

で定義する. ベクトル $\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_M) \in \mathbb{R}^M$ を**ラグランジュ乗数** (Lagrange multiplier) と呼ぶ.

定義 2.5.4: 双対問題

主問題 (primal problem) $\min_{\mathbf{x}} \{ f(\mathbf{x}) \mid \mathbf{x} \in \mathcal{C} \}$ に対して, ラグランジュ関数を用いた

$$\max_{\boldsymbol{\lambda}} \inf_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda})$$

を**双対問題** (dual problem) と呼ぶ. 一般に $\inf_{\mathbf{x}} L \leq f(\mathbf{x}^*)$ であるから, 双対問題の最適値は主問題の最適値以下である (**弱双対性**; weak duality). 等号が成り立つとき**強双対性** (strong duality) が成り立つという. 線形計画問題では, 主問題が実行可能解を持つならば強双対性が常に成り立つ.

2.5.2 離散版の双対問題

定義 2.5.5: 双対実行可能集合

コスト行列 $\mathbf{C} \in \mathbb{R}^{n \times m}$ に対して, **Kantorovich 双対ポテンシャル**の実行可能集合を

$$\mathbf{R}(\mathbf{C}) \stackrel{\text{def}}{=} \{ (\mathbf{f}, \mathbf{g}) \in \mathbb{R}^n \times \mathbb{R}^m \mid \forall (i, j), f_i + g_j \leq C_{i,j} \}$$

で定義する. ベクトル $\mathbf{f}, \mathbf{g}$ を**双対変数**または **Kantorovich ポテンシャル**と呼ぶ.

定理 2.5.6: Kantorovich 双対定理 (離散版)

ヒストグラム $\mathbf{a} \in \Sigma_n$, $\mathbf{b} \in \Sigma_m$ とコスト行列 $\mathbf{C} \in \mathbb{R}^{n \times m}$ に対して,

$$L_{\mathbf{C}}(\mathbf{a}, \mathbf{b}) = \max_{(\mathbf{f}, \mathbf{g}) \in \mathbf{R}(\mathbf{C})} \langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{g}, \mathbf{b} \rangle.$$

すなわち, Kantorovich 問題 (主問題) の最適値は双対問題の最適値に等しい.

Proof. Kantorovich 問題の主問題は

$$\min_{\mathbf{P} \geq 0} \{ \langle \mathbf{C}, \mathbf{P} \rangle \mid \mathbf{P} \mathbf{1}_m = \mathbf{a}, \mathbf{P}^\top \mathbf{1}_n = \mathbf{b} \}$$

である. 等式制約 $\mathbf{P} \mathbf{1}_m = \mathbf{a}$, $\mathbf{P}^\top \mathbf{1}_n = \mathbf{b}$ に対するラグランジュ乗数を $\mathbf{f} \in \mathbb{R}^n$, $\mathbf{g} \in \mathbb{R}^m$ とおくと, ラグランジュ関数は

$$L(\mathbf{P}, \mathbf{f}, \mathbf{g}) = \langle \mathbf{C}, \mathbf{P} \rangle + \langle \mathbf{f}, \mathbf{a} - \mathbf{P} \mathbf{1}_m \rangle + \langle \mathbf{g}, \mathbf{b} - \mathbf{P}^\top \mathbf{1}_n \rangle$$

となる. これを整理すると,

$$L(\mathbf{P}, \mathbf{f}, \mathbf{g}) = \langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{g}, \mathbf{b} \rangle + \langle \mathbf{C} - \mathbf{f} \mathbf{1}_m^\top - \mathbf{1}_n \mathbf{g}^\top, \mathbf{P} \rangle.$$

$\mathbf{P} \geq 0$ のもとで L を $\mathbf{P}$ について最小化すると, $C_{i,j} - f_i - g_j \geq 0$ (すなわち $f_i + g_j \leq C_{i,j}$) のとき最小値は $\langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{g}, \mathbf{b} \rangle$ であり, そうでなければ $-\infty$ となる. したがって双対問題は

$$\max_{(\mathbf{f}, \mathbf{g}) \in \mathbf{R}(\mathbf{C})} \langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{g}, \mathbf{b} \rangle$$

となる. 主問題は有界な実行可能領域を持つ線形計画であるから, 強双対性が成り立ち, 主問題と双対問題の最適値は一致する. $\square$

命題 2.5.7: 主双対最適性条件

$\mathbf{P}^*$ と $(\mathbf{f}^*, \mathbf{g}^*)$ がそれぞれ主問題と双対問題の最適解ならば, **相補性条件** (complementary slackness)

$$P_{i,j}^* > 0 \implies f_i^* + g_j^* = C_{i,j}$$

が成り立つ. すなわち, 最適輸送計画で正の質量が輸送される経路 (i, j) では, 双対ポテンシャルの和がコストに一致する.

Proof. 強双対性から $\langle \mathbf{C}, \mathbf{P}^* \rangle = \langle \mathbf{f}^*, \mathbf{a} \rangle + \langle \mathbf{g}^*, \mathbf{b} \rangle$ が成り立つ. 主問題の制約から $\langle \mathbf{f}^*, \mathbf{a} \rangle + \langle \mathbf{g}^*, \mathbf{b} \rangle = \langle \mathbf{f}^* \mathbf{1}_m^\top + \mathbf{1}_n \mathbf{g}^{*\top}, \mathbf{P}^* \rangle$ であるから,

$$\langle \mathbf{C} - \mathbf{f}^* \mathbf{1}_m^\top - \mathbf{1}_n \mathbf{g}^{*\top}, \mathbf{P}^* \rangle = 0.$$

$\mathbf{P}^* \geq 0$ かつ $C_{i,j} - f_i^* - g_j^* \geq 0$ であるから, 各成分の積が非負でその和が 0 となるためには, $P_{i,j}^* (C_{i,j} - f_i^* - g_j^*) = 0$ がすべての (i, j) で成り立たなければならない. $\square$

注意 2.5.8: 双対問題の経済学的解釈

双対問題は次のように解釈できる。輸送業者が、倉庫 i での集荷に f_i 、工場 j への配送に g_j の料金を設定し、元の輸送会社に代わってすべての輸送を引き受けるとする。輸送業者の収入は $\langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{g}, \mathbf{b} \rangle$ である。

輸送会社がこの契約を受け入れるためには、どの経路 (i, j) についても輸送業者の料金が自前の輸送コスト以下でなければならない： $f_i + g_j \leq C_{i,j}$ 。この条件のもとで輸送業者が収入を最大化する問題が双対問題であり、その最適値が最適輸送コストに一致する。

2.5.3 連続版の双対問題

離散版の双対問題では、制約 $f_i + g_j \leq C_{i,j}$ を満たすベクトルの組 $(\mathbf{f}, \mathbf{g})$ を最適化した。連続版では、これ関数の組 (f, g) に対する制約 $f(x) + g(y) \leq c(x, y)$ に置き換わる。このとき、 f が与えられたときに制約を満たす最良の g は $g(y) = \inf_x [c(x, y) - f(x)]$ で定まる。この操作を c -変換と呼ぶ。 c -変換により、双対問題を2つの関数 (f, g) ではなく1つの関数 f のみで記述できるようになる。

定義 2.5.9: c -変換

コスト関数 $c: \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R} \cup \{+\infty\}$ と関数 $f: \mathcal{X} \rightarrow \mathbb{R} \cup \{-\infty\}$ に対して、 f の c -変換 (c -transform) $f^c: \mathcal{Y} \rightarrow \mathbb{R} \cup \{-\infty\}$ を

$$f^c(y) \stackrel{\text{def}}{=} \inf_{x \in \mathcal{X}} [c(x, y) - f(x)]$$

で定義する。同様に、 $g: \mathcal{Y} \rightarrow \mathbb{R} \cup \{-\infty\}$ の $\bar{c}$ -変換 $g^{\bar{c}}: \mathcal{X} \rightarrow \mathbb{R} \cup \{-\infty\}$ を

$$g^{\bar{c}}(x) \stackrel{\text{def}}{=} \inf_{y \in \mathcal{Y}} [c(x, y) - g(y)]$$

で定義する。関数 f が $f = g^{\bar{c}}$ なる g をもつとき、 f は c -凸 (c -convex) であるという。

注意 2.5.10: c -変換と凸共役

$c(x, y) = \langle x, y \rangle$ ($\mathcal{X} = \mathcal{Y} = \mathbb{R}^d$) のとき、 $f^c(y) = \inf_x [\langle x, y \rangle - f(x)] = -\sup_x [f(x) - \langle x, y \rangle] = -f^*(y)$ となる。ここで $f^*(y) = \sup_x [\langle x, y \rangle - f(x)]$ は凸解析におけるルジャンドル–フェンシエル変換 (Legendre–Fenchel transform) である。すなわち、 c -変換はルジャンドル変換のコスト関数 c への一般化である。

定理 2.5.11: Kantorovich 双対定理 (連続版)

ポーランド空間 $\mathcal{X}, \mathcal{Y}$ 上の確率測度 α, β と下半連続なコスト関数 $c: \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}_+ \cup \{+\infty\}$ に対して、

$$\mathcal{L}_c(\alpha, \beta) = \sup_{\substack{f \in L^1(\alpha), g \in L^1(\beta) \\ f(x) + g(y) \leq c(x, y)}} \int_{\mathcal{X}} f d\alpha + \int_{\mathcal{Y}} g d\beta.$$

さらに、双対問題の最適解 (f^*, g^*) が存在し、 $g^* = f^{*c}$ と取れる。

注意 2.5.12: 制約なし双対

c -変換を用いると、双対問題を f のみの制約なし最適化として書き直せる：

$$\mathcal{L}_c(\alpha, \beta) = \sup_f \left\{ \int_{\mathcal{X}} f \, d\alpha + \int_{\mathcal{Y}} f^c \, d\beta \right\}.$$

制約 $f(x) + g(y) \leq c(x, y)$ は $g = f^c$ と置くことで自動的に満たされる．この定式化はエントロピー正則化（第 4 章）や半離散最適輸送の計算において重要な役割を果たす．

2.6 特殊な場合

最適輸送は一般には計算が困難であるが、特定の設定では閉じた形の解や効率的な計算法が得られる．

2.6.1 全変動距離との関係

コスト関数の選び方によって、最適輸送コストは既知の確率分布間の距離と一致する．

注意 2.6.1: Kronecker コスト関数と全変動

有限集合 $X = \{x_1, \dots, x_n\}$ 上の 2 つのヒストグラム $\mathbf{a}, \mathbf{b} \in \Sigma_n$ を考える．コスト行列を $C_{i,j} = 1 - \delta_{i,j}$ ($i = j$ のとき 0, $i \neq j$ のとき 1) と取ると、

$$L_C(\mathbf{a}, \mathbf{b}) = \frac{1}{2} \|\mathbf{a} - \mathbf{b}\|_1 = \frac{1}{2} \sum_{i=1}^n |a_i - b_i|.$$

右辺は**全変動距離** (total variation distance) に等しい．すなわち、移動先を区別しないコスト（同じ場所なら 0, 異なれば 1）のもとでの最適輸送コストは、どれだけの質量を「動かす必要があるか」のみを測り、基底空間の幾何学的構造は反映しない．

2.6.2 1 次元の場合

$\mathcal{X} = \mathcal{Y} = \mathbb{R}$ の場合、最適輸送には美しい閉じた形の解が存在する．この結果は累積分布関数と分位関数を用いて述べられる．

定義 2.6.2: 累積分布関数

$\mathbb{R}$ 上の確率測度 α に対して、**累積分布関数** (cumulative distribution function; CDF) を

$$F_\alpha(x) \stackrel{\text{def}}{=} \alpha((-\infty, x]) = \int_{-\infty}^x d\alpha$$

で定義する． F_α は右連続かつ単調非減少であり、 $\lim_{x \rightarrow -\infty} F_\alpha(x) = 0$, $\lim_{x \rightarrow +\infty} F_\alpha(x) = 1$ を満たす．

定義 2.6.3: 分位関数

累積分布関数 F_α に対して, **分位関数** (quantile function) または**一般化逆関数**を

$$F_\alpha^{-1}(r) \stackrel{\text{def}}{=} \inf \{x \in \mathbb{R} \mid F_\alpha(x) \geq r\} \quad (r \in (0, 1])$$

で定義する. F_α が狭義単調増加であるとき, F_α^{-1} は通常の逆関数に一致する.

定理 2.6.4: 1 次元の最適輸送

$\mathbb{R}$ 上の確率測度 α, β と実数 $p \geq 1$ に対して,

$$\mathcal{W}_p(\alpha, \beta)^p = \int_0^1 |F_\alpha^{-1}(r) - F_\beta^{-1}(r)|^p dr.$$

さらに, 最適な Monge 写像は $T = F_\beta^{-1} \circ F_\alpha$ で与えられる.

Proof. $T = F_\beta^{-1} \circ F_\alpha$ が α から β への Monge 写像であることを確認する. $r \in (0, 1)$ に対して, 分位関数の定義から $F_\alpha(F_\alpha^{-1}(r)) \geq r$ かつ $F_\beta^{-1}(F_\beta(y)) \leq y$ が成り立つ. 任意のボレル集合 $B \subset \mathbb{R}$ に対して,

$$\begin{aligned} (T_\# \alpha)(B) &= \alpha(T^{-1}(B)) = \alpha(\{x \mid F_\beta^{-1}(F_\alpha(x)) \in B\}) \\ &= \alpha(\{x \mid F_\alpha(x) \in F_\beta(B)\}). \end{aligned}$$

ここで, $[0, 1]$ 上の一様分布を λ とすると, F_α^{-1} が λ から α への Monge 写像であること (すなわち $(F_\alpha^{-1})_\# \lambda = \alpha$) から, F_α は α を $[0, 1]$ 上の一様分布に移す. 同様に F_β^{-1} は λ を β に移すから, 合成 $T = F_\beta^{-1} \circ F_\alpha$ は α を β に移す: $T_\# \alpha = \beta$.

この T による輸送コストは

$$\int_{\mathbb{R}} |x - T(x)|^p d\alpha(x) = \int_0^1 |F_\alpha^{-1}(r) - F_\beta^{-1}(r)|^p dr$$

となる ($x = F_\alpha^{-1}(r)$ と変数変換). この値が Kantorovich 問題の最適値以下であること, および Kantorovich 問題の最適値がこの値以上であること (双対問題の実行可能解を構成すれば示せる) を合わせると, T が最適な Monge 写像であり, 上の積分が $\mathcal{W}_p(\alpha, \beta)^p$ に一致する. $\square$

注意 2.6.5

1 次元では, Wasserstein 距離は分位関数の L^p ノルムの差として表される. この等長性は高次元では成り立たず, 1 次元特有の性質である. 最適な Monge 写像は「 α の r -分位点を β の r -分位点に送る」という自然な対応である.

例 2.6.6: 1 次元の離散的な場合

$\alpha = \frac{1}{n} \sum_{i=1}^n \delta_{x_i}$, $\beta = \frac{1}{n} \sum_{i=1}^n \delta_{y_i}$ ($x_1 \leq \dots \leq x_n$, $y_1 \leq \dots \leq y_n$ と整列済み) のとき, 最適な割当は $\sigma(i) = i$ (順序を保つ対応) であり,

$$\mathcal{W}_p(\alpha, \beta)^p = \frac{1}{n} \sum_{i=1}^n |x_i - y_i|^p.$$

2.6.3 ガウス分布の場合

多次元ガウス分布間の $\mathcal{W}_2$ 距離には閉じた形の公式が存在する. まず必要な線形代数の概念を導入する.

定義 2.6.7: 正定値対称行列

対称行列 $\Sigma \in \mathbb{R}^{d \times d}$ ($\Sigma^\top = \Sigma$) が**正定値** (positive definite) であるとは, すべての $\mathbf{0} \neq \mathbf{v} \in \mathbb{R}^d$ に対して $\mathbf{v}^\top \Sigma \mathbf{v} > 0$ が成り立つことをいう. 正定値対称行列のすべての固有値は正である.

定義 2.6.8: 行列の平方根

正定値対称行列 Σ に対して, その**平方根** $\Sigma^{1/2}$ とは, $\Sigma^{1/2} \Sigma^{1/2} = \Sigma$ かつ $\Sigma^{1/2}$ 自身も正定値対称であるような一意的な行列をいう. 固有値分解 $\Sigma = \mathbf{U} \text{diag}(\lambda_1, \dots, \lambda_d) \mathbf{U}^\top$ を用いると, $\Sigma^{1/2} = \mathbf{U} \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_d}) \mathbf{U}^\top$ で与えられる. $\Sigma^{-1/2}$ は $\Sigma^{1/2}$ の逆行列を表す.

定義 2.6.9: 多次元ガウス分布

$\mathbb{R}^d$ 上の**ガウス分布** (Gaussian distribution) $\mathcal{N}(\mathbf{m}, \Sigma)$ は, 平均ベクトル $\mathbf{m} \in \mathbb{R}^d$ と正定値対称行列である共分散行列 $\Sigma \in \mathbb{R}^{d \times d}$ によって定まる確率分布であり, 密度関数

$$\rho(x) = \frac{1}{(2\pi)^{d/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{1}{2}(x - \mathbf{m})^\top \Sigma^{-1}(x - \mathbf{m})\right)$$

を持つ.

定理 2.6.10: ガウス分布間の Wasserstein 距離

$\alpha = \mathcal{N}(\mathbf{m}_\alpha, \Sigma_\alpha)$, $\beta = \mathcal{N}(\mathbf{m}_\beta, \Sigma_\beta)$ に対して,

$$\mathcal{W}_2(\alpha, \beta)^2 = \|\mathbf{m}_\alpha - \mathbf{m}_\beta\|_2^2 + \mathcal{B}(\Sigma_\alpha, \Sigma_\beta)^2$$

が成り立つ. ここで $\mathcal{B}$ は **Bures 距離** であり,

$$\mathcal{B}(\Sigma_\alpha, \Sigma_\beta)^2 \stackrel{\text{def}}{=} \text{tr}\left(\Sigma_\alpha + \Sigma_\beta - 2\left(\Sigma_\alpha^{1/2} \Sigma_\beta \Sigma_\alpha^{1/2}\right)^{1/2}\right)$$

で定義される. また, 最適な Monge 写像は線形写像

$$T(x) = \mathbf{m}_\beta + \mathbf{A}(x - \mathbf{m}_\alpha), \quad \mathbf{A} = \Sigma_\alpha^{-1/2} \left(\Sigma_\alpha^{1/2} \Sigma_\beta \Sigma_\alpha^{1/2}\right)^{1/2} \Sigma_\alpha^{-1/2}$$

で与えられる.

注意 2.6.11

ガウス分布間の Wasserstein 距離は, 平均の差のユークリッドノルムと共分散行列の差を測る Bures 距離に分解される. 1 次元 ($d = 1$) では $\Sigma_\alpha = \sigma_\alpha^2$, $\Sigma_\beta = \sigma_\beta^2$ であるから,

$$\mathcal{W}_2(\alpha, \beta)^2 = (m_\alpha - m_\beta)^2 + (\sigma_\alpha - \sigma_\beta)^2$$

となり, 平均-標準偏差平面上のユークリッド距離に一致する.

2.7 Brenier の定理

Monge 問題と Kantorovich 問題の関係について, 二次コストの場合に両者が同値であるという深い結果を述べる.

定義 2.7.1: 凸関数

$\mathbb{R}^d$ 上の関数 $\varphi: \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ が凸 (convex) であるとは, 任意の $x, y \in \mathbb{R}^d$ と $t \in [0, 1]$ に対して

$$\varphi(tx + (1-t)y) \leq t\varphi(x) + (1-t)\varphi(y)$$

が成り立つことをいう.

定義 2.7.2: 凸関数の勾配

凸関数 $\varphi: \mathbb{R}^d \rightarrow \mathbb{R}$ が点 x で微分可能であるとき, その勾配 (gradient) $\nabla\varphi(x) \in \mathbb{R}^d$ は

$$\varphi(y) \geq \varphi(x) + \langle \nabla\varphi(x), y - x \rangle \quad (\forall y \in \mathbb{R}^d)$$

を満たす. 凸関数はほとんどいたるところ微分可能である (Rademacher の定理).

定理 2.7.3: Brenier の定理

$\alpha, \beta \in \mathcal{M}_+^1(\mathbb{R}^d)$ をコスト $c(x, y) = \|x - y\|_2^2$ に対する最適輸送問題の入力とする. α がルベーグ測度に関して密度を持つ (すなわち $\alpha \ll dx$) と仮定する. このとき, 以下が成り立つ:

1. 最適なカップリング π^* は一意的であり, Monge 写像によって誘導される: $\pi^* = (\text{Id}, T)_\# \alpha$.
2. 最適な Monge 写像 T は凸関数 $\varphi: \mathbb{R}^d \rightarrow \mathbb{R}$ の勾配として表される: $T(x) = \nabla\varphi(x)$ (α -a.e.).
3. この φ は α -a.e. の意味で一意的であり, $(\nabla\varphi)_\# \alpha = \beta$ を満たす.

注意 2.7.4

Brenier の定理の意義は以下の点にある：

- Kantorovich 緩和が**タイト**である：最適カップリングは Monge 写像のグラフ上に集中しており、質量の分割は起こらない。
- 最適写像が凸関数の勾配で特徴づけられるため、最適輸送と**凸解析**の間に深い関係が成立する。
- ソース測度 α が密度を持つという条件は本質的である。 α が離散測度の場合、最適な Monge 写像が存在するとは限らない（2.2.2 節の例 2.2.11 を参照）。

注意 2.7.5: Monge–Ampère 方程式

α, β がともに密度 ρ_α, ρ_β を持つとき、Brenier の定理における凸関数 φ は **Monge–Ampère 方程式**

$$\det(\partial^2 \varphi(x)) \rho_\beta(\nabla \varphi(x)) = \rho_\alpha(x)$$

を満たす。ここで $\partial^2 \varphi(x) \in \mathbb{R}^{d \times d}$ は φ の二階偏導関数を成分とする行列 $(\partial^2 \varphi)_{k,l} = \frac{\partial^2 \varphi}{\partial x_k \partial x_l}$ である。これは変位 $\varphi = \frac{\|\cdot\|^2}{2} + \varepsilon \psi$ が小さいとき $\det(\partial^2 \varphi) \approx 1 + \varepsilon \Delta \psi$ と線形化されることから、Monge–Ampère 作用素は非線形の退化ラプラシアンとみなせる。一般の測度に対しては古典的な意味の解が存在しないため、Alexandrov 解の枠組みが必要となる。

第3章

アルゴリズムの基礎

本章では、離散最適輸送問題を解くためのアルゴリズムを扱う。第2章で定式化した Kantorovich 問題の離散版

$$L_C(\mathbf{a}, \mathbf{b}) = \min_{\mathbf{P} \in U(\mathbf{a}, \mathbf{b})} \langle \mathbf{C}, \mathbf{P} \rangle$$

およびその双対問題を、組合せ最適化と線形計画法の手法で解くことが目標である。

これらのアルゴリズムの起源は第二次世界大戦前後にまで遡る。Tolstoi (1930), Hitchcock (1941), Kantorovich (1942) による輸送問題の定式化に対し、Dantzig の単体法 (1947) が厳密な解法を初めて与えた。最適輸送問題は線形計画の特殊なケースであるが、最小コストフロー問題と等価であるという構造を持ち、この構造を利用した効率的なアルゴリズムが開発されてきた。

3.1 Kantorovich 問題の標準形

Kantorovich 問題を線形計画の標準形に変換する。行列 $\mathbf{P} \in \mathbb{R}^{n \times m}$ を列ごとに並べたベクトル $\mathbf{p} \in \mathbb{R}^{nm}$ ($\mathbf{p}$ の第 $i + n(j-1)$ 成分が $P_{i,j}$) を用いると、周辺分布の制約は

$$\mathbf{A}\mathbf{p} = \begin{bmatrix} \mathbf{a} \\ \mathbf{b} \end{bmatrix}, \quad \mathbf{A} = \begin{bmatrix} \mathbf{1}_n^\top \otimes \mathbf{I}_m \\ \mathbf{I}_n \otimes \mathbf{1}_m^\top \end{bmatrix} \in \mathbb{R}^{(n+m) \times nm}$$

と書ける。ここで $\otimes$ はクロネッカー積である。コスト行列 $\mathbf{C}$ も同様にベクトル $\mathbf{c} \in \mathbb{R}^{nm}$ に並べると、Kantorovich 問題は標準形の線形計画

$$L_C(\mathbf{a}, \mathbf{b}) = \min_{\substack{\mathbf{p} \in \mathbb{R}_+^{nm} \\ \mathbf{A}\mathbf{p} = [\mathbf{a}^\top, \mathbf{b}^\top]^\top}} \mathbf{c}^\top \mathbf{p}$$

と表される。

定義 3.1.1: クロネッカー積

行列 $\mathbf{A} \in \mathbb{R}^{p \times q}$ と $\mathbf{B} \in \mathbb{R}^{r \times s}$ のクロネッカー積 (Kronecker product) $\mathbf{A} \otimes \mathbf{B} \in \mathbb{R}^{pr \times qs}$ を、 (i, j) ブロックが $A_{i,j}\mathbf{B}$ であるブロック行列として定義する：

$$\mathbf{A} \otimes \mathbf{B} = \begin{pmatrix} A_{1,1}\mathbf{B} & \cdots & A_{1,q}\mathbf{B} \\ \vdots & \ddots & \vdots \\ A_{p,1}\mathbf{B} & \cdots & A_{p,q}\mathbf{B} \end{pmatrix}.$$

注意 3.1.2: 制約の冗長性

行列 $\mathbf{A}$ の $n + m$ 本の行のうち 1 本は冗長である．実際，最初の n 行の和と残りの m 行の和はいずれも $\mathbf{1}_{nm}^\top$ に等しく，これは $\sum_i a_i = \sum_j b_j = 1$ という条件に対応する．したがって $\mathbf{A}$ の階数は $n + m - 1$ であり，最適解を探索すべき $\mathbf{U}(\mathbf{a}, \mathbf{b})$ の頂点は最大 $n + m - 1$ 個の非零成分を持つ（命題 3.3.3）．

3.2 離散 C -変換

第 2 章で連続版の c -変換（定義 2.5.9）を導入した．ここではその離散版を定義し，双対問題を 1 変数の最適化に帰着させる性質を示す．

定義 3.2.1: 離散 C -変換

コスト行列 $\mathbf{C} \in \mathbb{R}^{n \times m}$ とベクトル $\mathbf{f} \in \mathbb{R}^n$ に対して， $\mathbf{f}$ の C -変換 $\mathbf{f}^C \in \mathbb{R}^m$ を

$$(\mathbf{f}^C)_j \stackrel{\text{def}}{=} \min_{i \in [n]} (C_{i,j} - f_i)$$

で定義する．同様に， $\mathbf{g} \in \mathbb{R}^m$ の $\bar{C}$ -変換 $\mathbf{g}^{\bar{C}} \in \mathbb{R}^n$ を

$$(\mathbf{g}^{\bar{C}})_i \stackrel{\text{def}}{=} \min_{j \in [m]} (C_{i,j} - g_j)$$

で定義する．

$\mathbf{f}$ を固定したとき， $f_i + g_j \leq C_{i,j}$ ($\forall i, j$) を満たす $\mathbf{g}$ のうち成分ごとに最大のものが $\mathbf{f}^C$ である．実際， $f_i + g_j \leq C_{i,j}$ がすべての i で成り立つことは $g_j \leq \min_i (C_{i,j} - f_i) = (\mathbf{f}^C)_j$ と同値であるから，制約を満たす最大の g_j は $(\mathbf{f}^C)_j$ に他ならない．さらに，任意の実行可能な $(\mathbf{f}, \mathbf{g})$ に対して $\mathbf{g} \leq \mathbf{f}^C$ であるから $\langle \mathbf{g}, \mathbf{b} \rangle \leq \langle \mathbf{f}^C, \mathbf{b} \rangle$ ($\mathbf{b} \geq 0$ による) が成り立つ．したがって，双対問題は $\mathbf{f}$ のみの最大化問題に帰着される：

$$L_{\mathbf{C}}(\mathbf{a}, \mathbf{b}) = \max_{\mathbf{f} \in \mathbb{R}^n} [\langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{f}^C, \mathbf{b} \rangle].$$

この定式化は半双対 (semi-dual) と呼ばれる．

C -変換と $\bar{C}$ -変換の交互適用には以下の性質がある．

命題 3.2.2: C -変換の性質

以下が成り立つ（不等号はすべて成分ごと）：

1. 単調性の反転： $\mathbf{f} \leq \mathbf{f}' \implies \mathbf{f}^C \geq \mathbf{f}'^C$ ．
2. 拡大性： $\mathbf{f}^{C\bar{C}} \geq \mathbf{f}$, $\mathbf{g}^{\bar{C}C} \geq \mathbf{g}$ ．
3. 冪等性： $\mathbf{f}^{C\bar{C}C} = \mathbf{f}^C$ ．

Proof. (1) $\mathbf{f} \leq \mathbf{f}'$ ならば各 j に対して $C_{i,j} - f_i \geq C_{i,j} - f'_i$ であるから， $\min_i (C_{i,j} - f_i) \geq \min_i (C_{i,j} - f'_i)$ ，すなわち $(\mathbf{f}^C)_j \geq (\mathbf{f}'^C)_j$ が成り立つ．

(2) $C\bar{C}$ -変換の定義を展開すると,

$$(\mathbf{f}^{C\bar{C}})_i = \min_j (C_{i,j} - (\mathbf{f}^C)_j) = \min_j \left(C_{i,j} - \min_{i'} (C_{i',j} - f_{i'}) \right).$$

$-\min_{i'} (C_{i',j} - f_{i'}) \geq -(C_{i,j} - f_i) = f_i - C_{i,j}$ であるから,

$$(\mathbf{f}^{C\bar{C}})_i \geq \min_j (C_{i,j} + f_i - C_{i,j}) = f_i.$$

$\mathbf{g}^{C\bar{C}} \geq \mathbf{g}$ も同様.

(3) $\mathbf{g} = \mathbf{f}^C$ とおくと, (2) より $\mathbf{g}^{\bar{C}} = \mathbf{f}^{C\bar{C}} \geq \mathbf{f}$ が成り立つ. (1) を適用すると $\mathbf{f}^{C\bar{C}C} \leq \mathbf{f}^C$ が得られる. 一方, (2) より $\mathbf{f}^{C\bar{C}C} \geq \mathbf{f}^C$ であるから, $\mathbf{f}^{C\bar{C}C} = \mathbf{f}^C$ が成り立つ. $\square$

注意 3.2.3

性質 (3) は, C -変換と $\bar{C}$ -変換を交互に適用しても 2 回目以降は改善が得られないことを意味する. すなわち, $\mathbf{f} \rightarrow \mathbf{f}^C \rightarrow \mathbf{f}^{C\bar{C}} \rightarrow \mathbf{f}^{C\bar{C}C} = \mathbf{f}^C \rightarrow \dots$ と停滞する. したがって, C -変換の交互適用だけでは最適解には到達できず, ネットワーク単体法やオークションアルゴリズムなどの手法が必要となる.

3.3 輸送多面体の頂点

線形計画の最適解は実行可能領域の頂点 (端点) で達成される. $\mathbf{U}(\mathbf{a}, \mathbf{b})$ の頂点の構造を理解することは, アルゴリズムの設計に不可欠である.

定義 3.3.1: 二部グラフ

ソース節点の集合 $V = \{1, \dots, n\}$ とターゲット節点の集合 $V' = \{1', \dots, m'\}$ に対して, V と V' の間のすべての辺 $\{(i, j') \mid i \in [n], j' \in [m]\}$ から成るグラフを完全二部グラフ (complete bipartite graph) と呼ぶ. 輸送計画 $\mathbf{P}$ の台グラフ (support graph) を, $P_{i,j} > 0$ なる辺 (i, j') から成るグラフ $G(\mathbf{P}) = (V \cup V', S(\mathbf{P}))$ で定義する.

定義 3.3.2: 閉路

グラフにおいて, 相異なる節点 $v_1, v_2, \dots, v_k$ と辺 $(v_1, v_2), (v_2, v_3), \dots, (v_{k-1}, v_k), (v_k, v_1)$ から成る経路を閉路 (cycle) と呼ぶ. 閉路を持たないグラフを森 (forest) といい, 連結な森を木 (tree) という.

命題 3.3.3: 頂点の木構造

$\mathbf{P}$ が $\mathbf{U}(\mathbf{a}, \mathbf{b})$ の頂点ならば, 台グラフ $G(\mathbf{P})$ は閉路を持たない (すなわち森である). 特に, $\mathbf{P}$ の非零成分の数は $n + m - 1$ 以下である.

Proof. 背理法による. $\mathbf{P}$ が頂点であり, かつ $G(\mathbf{P})$ が閉路 $(i_1, j'_1), (i_2, j'_1), (i_2, j'_2), \dots, (i_k, j'_k), (i_1, j'_k)$ を含むと仮定する.

閉路に沿って交互に $+\varepsilon$, $-\varepsilon$ の摂動を加えた行列 $\mathbf{E}$ を構成する. $\varepsilon > 0$ を閉路上の $\mathbf{P}$ の最小値より小さく取れば, $\mathbf{Q} = \mathbf{P} + \mathbf{E}$ および $\mathbf{R} = \mathbf{P} - \mathbf{E}$ はいずれも非負である. $\mathbf{E}$ の各行和・各列和は 0 であるから, $\mathbf{Q}, \mathbf{R} \in \mathbf{U}(\mathbf{a}, \mathbf{b})$ である. $\mathbf{P} = (\mathbf{Q} + \mathbf{R})/2$ かつ $\mathbf{Q} \neq \mathbf{P}$ であるから, $\mathbf{P}$ が頂点であることに矛盾する.

k 個の節点を持つ閉路のないグラフの辺数は $k - 1$ 以下であるから, $n + m$ 個の節点を持つ $G(\mathbf{P})$ の辺数 (= $\mathbf{P}$ の非零成分数) は $n + m - 1$ 以下である. $\square$

3.4 北西隅法

ネットワーク単体法などの反復法を初期化するには, $\mathbf{U}(\mathbf{a}, \mathbf{b})$ の頂点を 1 つ求める必要がある. 北西隅法 (north-west corner rule) は, 高々 $n + m$ 回の演算で頂点を構成する単純なヒューリスティックである.

Algorithm 1

Input: $\mathbf{a} \in \Sigma_n$, $\mathbf{b} \in \Sigma_m$

Output: $\mathbf{U}(\mathbf{a}, \mathbf{b})$ の頂点 $\mathbf{P}$

1. $i \leftarrow 1, j \leftarrow 1, r \leftarrow a_1, c \leftarrow b_1$
2. **while** $i \leq n$ かつ $j \leq m$ **do**:
3. $t \leftarrow \min(r, c), \quad P_{i,j} \leftarrow t$
4. $r \leftarrow r - t, \quad c \leftarrow c - t$
5. **if** $r = 0$: $i \leftarrow i + 1, r \leftarrow a_i$ ($i \leq n$ のとき)
6. **if** $c = 0$: $j \leftarrow j + 1, c \leftarrow b_j$ ($j \leq m$ のとき)

例 3.4.1: 北西隅法の実行例

$\mathbf{a} = (0.2, 0.5, 0.3)$, $\mathbf{b} = (0.5, 0.1, 0.4)$ のとき:

$$\begin{pmatrix} 0.2 & 0 & 0 \\ 0.3 & 0.1 & 0.1 \\ 0 & 0 & 0.3 \end{pmatrix}.$$

非零成分は $5 = 3 + 3 - 1$ 個であり, 台グラフは閉路を持たないので, これは $\mathbf{U}(\mathbf{a}, \mathbf{b})$ の頂点である.

3.5 ネットワーク単体法

ネットワーク単体法 (network simplex) は, 最適輸送問題に特化した単体法の変種であり, 輸送多面体の頂点間を移動しながら最適解を探索する. 以下の 3 つの操作を反復する.

3.5.1 相補的な双対変数の構成

$\mathbf{U}(\mathbf{a}, \mathbf{b})$ の頂点 $\mathbf{P}$ が与えられたとき, $\mathbf{P}$ と相補的 (complementary) な双対変数 $(\mathbf{f}, \mathbf{g})$ を求める. すなわち, $P_{i,j} > 0$ なるすべての (i, j) に対して $f_i + g_j = C_{i,j}$ を満たす $(\mathbf{f}, \mathbf{g})$ を構成する.

命題 3.3.3 から、 $G(\mathbf{P})$ は森であり辺数は $n + m - 1$ 以下である。各連結成分（木）において、1 つの節点の双対変数を 0 に設定し、木の幅優先探索（または深さ優先探索）により残りの変数を $f_i + g_j = C_{i,j}$ から逐次的に定める。

3.5.2 最適性の判定と更新

得られた $(\mathbf{f}, \mathbf{g})$ が**双対実行可能** ($f_i + g_j \leq C_{i,j}, \forall i, j$) であれば、主双対最適性条件（命題 2.5.7）から $\mathbf{P}$ は最適であり、アルゴリズムは終了する。

双対実行可能でない場合、 $f_i + g_j > C_{i,j}$ となる辺 (i, j') が存在する。この辺を $G(\mathbf{P})$ に追加すると、以下の 2 つの場合が起こりうる：

1. **閉路が生じない場合**： G は依然として森であり、 $(\mathbf{f}, \mathbf{g})$ を再計算する。 $\mathbf{P}$ は変更されない（退化ステップ）。
2. **閉路が生じる場合**：閉路に沿って流量を調整する。閉路上の「正方向」の辺では $P_{i,j}$ を θ だけ増加させ、「負方向」の辺では θ だけ減少させる。 θ は負方向の辺の最小流量に等しく、流量が 0 になった辺を G から除去する。

3.5.3 コストの改善

閉路が生じた場合にコストが改善されることを示す。閉路を $(i_1, j'_1), (j'_1, i_2), (i_2, j'_2), \dots, (i_l, j'_l), (j'_l, i_1)$ と書き、 $i_1 = i, j_1 = j$ （追加した辺）とする。更新後の $\tilde{\mathbf{P}}$ は正方向の辺で θ 増加、負方向の辺で θ 減少するから、

$$\langle \tilde{\mathbf{P}}, \mathbf{C} \rangle - \langle \mathbf{P}, \mathbf{C} \rangle = \theta \left(\sum_{k=1}^l C_{i_k, j_k} - \sum_{k=1}^l C_{i_{k+1}, j_k} \right).$$

$(\mathbf{f}, \mathbf{g})$ は $\mathbf{P}$ に相補的であるから、既存の辺 (i_k, j'_k) ($k \geq 2$) と (i_{k+1}, j'_k) について $f_{i_k} + g_{j_k} = C_{i_k, j_k}$ および $f_{i_{k+1}} + g_{j_k} = C_{i_{k+1}, j_k}$ が成り立つ。これらを代入すると、差は打ち消し合い

$$\sum_{k=1}^l C_{i_k, j_k} - \sum_{k=1}^l C_{i_{k+1}, j_k} = C_{i, j} - (f_i + g_j)$$

が得られる。 (i, j) は $f_i + g_j > C_{i,j}$ なる辺として選ばれたから、 $C_{i,j} - (f_i + g_j) < 0$ であり、 $\theta > 0$ ならばコストは厳密に減少する。

注意 3.5.1: 計算量

ネットワーク単体法は多項式時間で停止することが Orlin (1997) により証明された。Tarjan (1997) は効率的なデータ構造を用いて $O((n+m)nm \log(n+m) \log((n+m)\|\mathbf{C}\|_\infty))$ の計算量を達成した。

3.6 オークションアルゴリズム

オークションアルゴリズム (auction algorithm) は Bertsekas (1981) により提案された、最適割当問題 ($n = m$, 均一重み) に特化した双対的手法である。

3.6.1 ε -相補性条件

最適割当問題（設定 2.2.3）の最適解 σ^* と最適双対変数 $\mathbf{g}^*$ は

$$C_{i,\sigma^*(i)} - g_{\sigma^*(i)}^* = \min_j (C_{i,j} - g_j^*) \quad (\forall i \in \llbracket n \rrbracket)$$

を満たす（ c -変換と相補性条件から従う）。

オークションアルゴリズムはこの条件の近似版を用いる。

定義 3.6.1: ε -相補性条件

部分割当 (S, ξ) ($S \subset \llbracket n \rrbracket$, $\xi: S \rightarrow \llbracket n \rrbracket$ は単射) と双対変数 $\mathbf{g} \in \mathbb{R}^n$ が ε -相補性条件 (ε -complementary slackness; ε -CS) を満たすとは、すべての $i \in S$ に対して

$$C_{i,\xi(i)} - g_{\xi(i)} \leq \varepsilon + \min_j (C_{i,j} - g_j)$$

が成り立つことをいう。

3.6.2 アルゴリズムの更新規則

未割当の $i \notin S$ に対して、調整コスト $C_{i,j} - g_j$ の最小値と第 2 最小値を達成する添字を

$$j_i^1 \in \arg \min_j (C_{i,j} - g_j), \quad j_i^2 \in \arg \min_{j \neq j_i^1} (C_{i,j} - g_j)$$

とする。以下の更新を行う：

1. $\mathbf{g}$ の更新：

$$g_{j_i^1} \leftarrow g_{j_i^1} - \left[(C_{i,j_i^2} - g_{j_i^2}) - (C_{i,j_i^1} - g_{j_i^1}) + \varepsilon \right].$$

括弧内は第 2 最小値と最小値の差に ε を加えたものであり、常に $\geq \varepsilon > 0$ である。

2. S と ξ の更新： j_i^1 に既に割当てられている i' ($\xi(i') = j_i^1$) があれば S から i' を除去する。 $\xi(i) = j_i^1$ として i を S に追加する。

命題 3.6.2: ε -CS の保存

各反復後も ε -CS 条件は保たれる。

Proof. 更新前に ε -CS が成り立つとする。更新後の双対変数を $\mathbf{g}^n$ と書く。 $\mathbf{g}^n$ は $\mathbf{g}$ から j_i^1 成分のみ減少させたものであるから $\mathbf{g}^n \leq \mathbf{g}$ (成分ごと) が成り立つ。

新たに追加された i について、更新の定義から $C_{i,j_i^1} - g_{j_i^1}^n = \varepsilon + (C_{i,j_i^2} - g_{j_i^2}) = \varepsilon + \min_{j \neq j_i^1} (C_{i,j} - g_j)$ であるから、 $\mathbf{g}^n \leq \mathbf{g}$ より $C_{i,j_i^1} - g_{j_i^1}^n \leq \varepsilon + \min_j (C_{i,j} - g_j^n)$ が成り立つ。

$i' \neq i$ ($i' \in S$) について、割当は変わらず $\mathbf{g}^n \leq \mathbf{g}$ であるから $C_{i',\xi(i')} - g_{\xi(i')}^n = C_{i',\xi(i')} - g_{\xi(i')} \leq \varepsilon + \min_j (C_{i',j} - g_j) \leq \varepsilon + \min_j (C_{i',j} - g_j^n)$ が成り立つ。 $\square$

命題 3.6.3: 反復回数の上界

オークションアルゴリズムは最大 $n\|\mathbf{C}\|_\infty/\varepsilon$ 回の反復で停止する.

Proof. アルゴリズムが $T > n\|\mathbf{C}\|_\infty/\varepsilon$ 回反復して停止しないと仮定する. すると, ξ の像に入っていない添字 j (一度も割当先にならなかった) が存在し, $g_j = 0$ のままである. 一方, ある添字 j' が n 回以上更新されたとすると, 各更新で $g_{j'}$ は少なくとも ε 減少するから $g_{j'} \leq -n\varepsilon < -\|\mathbf{C}\|_\infty$ となる. このとき, 任意の i に対して $C_{i,j'} - g_{j'} > \|\mathbf{C}\|_\infty + \|\mathbf{C}\|_\infty \geq C_{i,j} + \|\mathbf{C}\|_\infty > C_{i,j} - g_j$ であるから, j' が $j_i^1 = \arg \min_j (C_{i,j} - g_j)$ となることはない. これは j' がさらに更新されることに矛盾する. したがって, 各添字の更新回数は $\|\mathbf{C}\|_\infty/\varepsilon$ 以下であり, 全体の反復回数は $n\|\mathbf{C}\|_\infty/\varepsilon$ 以下である. $\square$

命題 3.6.4: 近似最適性

オークションアルゴリズムの出力する割当のコストは, 最適値に対して $n\varepsilon$ 以内の近似解である.

Proof. 最適割当を σ^* , 最適双対変数を $\mathbf{g}^*$ とし, 最適値を $t^* = \sum_i C_{i,\sigma^*(i)} = \sum_i \min_j (C_{i,j} - g_j^*) + \sum_j g_j^*$ と書く. アルゴリズム終了時の割当 ξ と双対変数 $\mathbf{g}$ に対して, $\mathbf{g}$ の双対実行可能性 ($\mathbf{g} \leq \mathbf{g}^*$ の意味での劣最適性) から

$$t^* \geq \sum_i \min_j (C_{i,j} - g_j) + \sum_j g_j.$$

ε -CS 条件 $C_{i,\xi(i)} - g_{\xi(i)} \leq \varepsilon + \min_j (C_{i,j} - g_j)$ を用いると,

$$\sum_i \min_j (C_{i,j} - g_j) \geq \sum_i (C_{i,\xi(i)} - g_{\xi(i)} - \varepsilon).$$

ξ は全単射であるから $\sum_i g_{\xi(i)} = \sum_j g_j$ が成り立ち,

$$t^* \geq \sum_i C_{i,\xi(i)} - n\varepsilon.$$

一方 $\sum_i C_{i,\xi(i)} \geq t^*$ (ξ は一般に最適でないから) より, $t^* \leq \sum_i C_{i,\xi(i)} \leq t^* + n\varepsilon$ が得られる. $\square$

注意 3.6.5: ε -スケーリング

ε を徐々に減少させる ε -スケーリングを用いると, 計算量は $O(n^3 \log \|\mathbf{C}\|_\infty)$ に改善される.

3.7 双対上昇法

ネットワーク単体法が主問題の頂点を更新するのに対し, **双対上昇法** (dual ascent method) は双対変数 $(\mathbf{f}, \mathbf{g})$ を直接改善する手法であり, その起源は Borchardt (1865) にまで遡る. König-Egerváry の定理や Kuhn (1955) によるハンガリアン法 (Hungarian algorithm) はこの枠組みの代表例である.

3.7.1 均衡辺と不活性辺

双対変数 $(\mathbf{f}, \mathbf{g}) \in \mathbf{R}(\mathbf{C})$ が与えられたとき、辺 (i, j) が**均衡** (balanced) であるとは $f_i + g_j = C_{i,j}$ が成り立つことをいい、 $f_i + g_j < C_{i,j}$ のとき**不活性** (inactive) であるという。均衡辺から成る部分グラフを $G_{\mathbf{f}, \mathbf{g}}$ と記す。

3.7.2 双対上昇ステップ

$(\mathbf{f}, \mathbf{g})$ が最適でない場合、双対目的関数 $\langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{g}, \mathbf{b} \rangle$ を改善する方向が存在する。

集合 $S \subset \llbracket n \rrbracket$, $S' \subset \llbracket m \rrbracket$ を、均衡辺グラフ $G_{\mathbf{f}, \mathbf{g}}$ における**到達可能性**から定める。具体的には、 S 内のソース節点 i から出る均衡辺のターゲット側の節点がすべて S' に含まれるように S, S' を選ぶ。このとき、 $\varepsilon > 0$ を十分小さく取れば、摂動した双対変数

$$(\tilde{\mathbf{f}}, \tilde{\mathbf{g}}) = (\mathbf{f}, \mathbf{g}) + \varepsilon(\mathbf{1}_S, -\mathbf{1}_{S'})$$

は双対実行可能である。ここで $(\mathbf{1}_S)_i = 1$ ($i \in S$)、 0 ($i \notin S$) である。双対目的関数の変化量は

$$\varepsilon \left(\sum_{i \in S} a_i - \sum_{j \in S'} b_j \right)$$

であり、 $\sum_{i \in S} a_i > \sum_{j \in S'} b_j$ となる S, S' を選べば改善が得られる。このような S, S' は、均衡辺グラフ上の最大フロー (Ford-Fulkerson アルゴリズム等) から構成できる。

注意 3.7.1: ネットワーク単体法との比較

ネットワーク単体法は主問題の**実行可能**な頂点を維持し、最適性条件 (双対実行可能性) は収束時にのみ達成される。双対上昇法は逆に、双対実行可能性を維持しつつ、主問題の実行可能性 (周辺分布制約) は収束時にのみ達成される。割当問題 ($n = m$, 均一重み) の場合、双対上昇法はハンガリアン法に帰着する。

第 4 章

エントロピー正則化

第 3 章で扱った古典的アルゴリズム（ネットワーク単体法，オークションアルゴリズム）は厳密解を与えるが，問題サイズが大きくなると計算コストが高い．**エントロピー正則化**（entropic regularization）は，最適輸送問題にエントロピー項を加えることで問題を厳密に凸化し，行列スケーリングの反復（Sinkhorn アルゴリズム）で効率的に近似解を得る手法である．この手法は GPU 並列化と相性が良く，大規模な最適輸送の計算を実用的にした鍵となる技術である．

4.1 エントロピー正則化

定義 4.1.1: 離散エントロピー

行列 $\mathbf{P} \in \mathbb{R}_+^{n \times m}$ の**離散エントロピー**（discrete entropy）を

$$H(\mathbf{P}) \stackrel{\text{def}}{=} - \sum_{i,j} P_{i,j} (\log P_{i,j} - 1)$$

で定義する．ただし $0 \log 0 = 0$ と約束する． $P_{i,j} < 0$ となる成分が存在する場合は $H(\mathbf{P}) = -\infty$ と定める．

注意 4.1.2: 定義の動機

通常の Shannon エントロピー $-\sum_{i,j} P_{i,j} \log P_{i,j}$ との違いは $\sum_{i,j} P_{i,j}$ の項のみである． $P_{i,j}(\log P_{i,j} - 1)$ という形を採用する理由は主に 2 つある．第一に，対応する負エントロピー $-H$ の勾配が $\partial(-H)/\partial P_{i,j} = \log P_{i,j}$ と簡潔になり，KKT 条件から最適解の構造が直接読み取れる．第二に，この形式は非正規化測度に対しても自然に定義される一般化 KL ダイバージェンス（定義 4.1.5）と整合する．Gibbs カーネル $K_{i,j} = e^{-C_{i,j}/\varepsilon}$ は一般に $\sum_{i,j} K_{i,j} \neq 1$ であるため，正則化問題を KL 射影として書き直す（4.1.1 節）際にこの一般化が本質的に必要となる．

$-H$ は狭義凸関数である．実際， $\mathbf{P}, \mathbf{Q} \in \mathbb{R}_+^{n \times m}$ ($\mathbf{P} \neq \mathbf{Q}$) と $t \in (0, 1)$ に対して， $-x(\log x - 1)$ の狭義凸性から $-H(t\mathbf{P} + (1-t)\mathbf{Q}) < -tH(\mathbf{P}) - (1-t)H(\mathbf{Q})$ が成り立つ．

設定 4.1.3: 正則化された最適輸送

ヒストグラム $\mathbf{a} \in \Sigma_n$, $\mathbf{b} \in \Sigma_m$, コスト行列 $\mathbf{C} \in \mathbb{R}_+^{n \times m}$, および正則化パラメータ $\varepsilon > 0$ に対して, エントロピー正則化された最適輸送問題を

$$L_{\mathbf{C}}^{\varepsilon}(\mathbf{a}, \mathbf{b}) \stackrel{\text{def}}{=} \min_{\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})} \langle \mathbf{C}, \mathbf{P} \rangle - \varepsilon H(\mathbf{P})$$

で定義する. 上述のように目的関数は $\mathbf{P} > 0$ で狭義凸であるから, 最適解 $\mathbf{P}_{\varepsilon}$ は一意的に存在する.

注意 4.1.4: ε の役割

正則化パラメータ ε は以下のように 2 つの極限を補間する:

- $\varepsilon \rightarrow 0$ のとき, $\mathbf{P}_{\varepsilon}$ は非正則化問題 $L_{\mathbf{C}}$ の最適解のうちエントロピーが最大のものに収束する.
- $\varepsilon \rightarrow +\infty$ のとき, $\mathbf{P}_{\varepsilon}$ は積測度 $\mathbf{a}\mathbf{b}^{\top}$ に収束する (ソースとターゲットを独立に結合するカップリング).

4.1.1 KL ダイバージェンスによる定式化

定義 4.1.5: Kullback–Leibler ダイバージェンス

非負ベクトル $\mathbf{p}, \mathbf{q} \in \mathbb{R}_+^d$ に対して, **KL ダイバージェンス** (Kullback–Leibler divergence) を

$$\text{KL}(\mathbf{p} \parallel \mathbf{q}) \stackrel{\text{def}}{=} \sum_k \left(p_k \log \frac{p_k}{q_k} - p_k + q_k \right)$$

で定義する. ただし $0 \log 0 = 0$, $0 \log(0/0) = 0$ と約束する. $\text{KL}(\mathbf{p} \parallel \mathbf{q}) \geq 0$ であり, 等号は $\mathbf{p} = \mathbf{q}$ のときかつそのときに限る. 行列 $\mathbf{P}, \mathbf{K} \in \mathbb{R}_+^{n \times m}$ に対しては, 成分を一行に並べたベクトルに対する KL ダイバージェンスとして $\text{KL}(\mathbf{P} \parallel \mathbf{K})$ を定める.

定義 4.1.6: Gibbs カーネル

コスト行列 $\mathbf{C}$ と正則化パラメータ $\varepsilon > 0$ に対して, **Gibbs カーネル**を

$$K_{i,j} \stackrel{\text{def}}{=} e^{-C_{i,j}/\varepsilon}$$

で定義する. ε が小さいほど, コストが大きい成分は指数的に小さくなる.

Gibbs カーネルを用いると, 正則化問題は KL 射影として書き直せる:

$$\mathbf{P}_{\varepsilon} = \arg \min_{\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})} \text{KL}(\mathbf{P} \parallel \mathbf{K}).$$

すなわち, $\mathbf{P}_{\varepsilon}$ は Gibbs カーネル $\mathbf{K}$ からカップリング集合 $\mathbf{U}(\mathbf{a}, \mathbf{b})$ への KL 射影である.

4.2 Sinkhorn アルゴリズム

4.2.1 最適解の構造

命題 4.2.1: スケーリング形式

正則化問題の最適解 $\mathbf{P}_\varepsilon$ は

$$(P_\varepsilon)_{i,j} = u_i K_{i,j} v_j$$

の形で表される．ここで $\mathbf{u} \in \mathbb{R}_+^n$, $\mathbf{v} \in \mathbb{R}_+^m$ は正のスケーリングベクトルである．行列形式では $\mathbf{P}_\varepsilon = \text{diag}(\mathbf{u}) \mathbf{K} \text{diag}(\mathbf{v})$ と書ける．

Proof. ラグランジュ関数を

$$\mathcal{L}(\mathbf{P}, \mathbf{f}, \mathbf{g}) = \langle \mathbf{C}, \mathbf{P} \rangle - \varepsilon H(\mathbf{P}) - \langle \mathbf{f}, \mathbf{P} \mathbf{1}_m - \mathbf{a} \rangle - \langle \mathbf{g}, \mathbf{P}^\top \mathbf{1}_n - \mathbf{b} \rangle$$

とおく． $P_{i,j} > 0$ (エントロピー項が $P_{i,j} = 0$ を排除する) における一次条件 $\partial \mathcal{L} / \partial P_{i,j} = 0$ は

$$C_{i,j} + \varepsilon \log P_{i,j} - f_i - g_j = 0$$

であり，これを解くと $P_{i,j} = e^{f_i/\varepsilon} e^{-C_{i,j}/\varepsilon} e^{g_j/\varepsilon} = u_i K_{i,j} v_j$ が得られる．ここで $u_i = e^{f_i/\varepsilon}$, $v_j = e^{g_j/\varepsilon}$ とおいた． $\square$

4.2.2 Sinkhorn の反復

周辺分布の制約 $\mathbf{P} \mathbf{1}_m = \mathbf{a}$, $\mathbf{P}^\top \mathbf{1}_n = \mathbf{b}$ にスケーリング形式を代入すると，

$$\mathbf{u} \odot (\mathbf{K} \mathbf{v}) = \mathbf{a}, \quad \mathbf{v} \odot (\mathbf{K}^\top \mathbf{u}) = \mathbf{b}$$

が得られる ($\odot$ はアダマール積)．Sinkhorn アルゴリズムは，この2つの条件を交互に満たすよう $\mathbf{u}$ と $\mathbf{v}$ を更新する．

Algorithm 1

Input: $\mathbf{a} \in \Sigma_n$, $\mathbf{b} \in \Sigma_m$, $\mathbf{K} = e^{-\mathbf{C}/\varepsilon}$, 反復回数 L

Output: スケーリングベクトル $\mathbf{u}, \mathbf{v}$

1. $\mathbf{v}^{(0)} \leftarrow \mathbf{1}_m$
2. **for** $\ell = 0, 1, \dots, L-1$ **do**:
3. $\mathbf{u}^{(\ell+1)} \leftarrow \mathbf{a} \oslash (\mathbf{K} \mathbf{v}^{(\ell)})$
4. $\mathbf{v}^{(\ell+1)} \leftarrow \mathbf{b} \oslash (\mathbf{K}^\top \mathbf{u}^{(\ell+1)})$

ここで $\oslash$ は成分ごとの除算を表す．

各反復は行列ベクトル積 $\mathbf{K} \mathbf{v}$ および $\mathbf{K}^\top \mathbf{u}$ を計算するだけであり， $O(nm)$ の計算量で済む．

注意 4.2.2: Bregman 射影としての解釈

Sinkhorn の各ステップは、KL ダイバージェンスに関する交互射影と解釈できる。すなわち、

$$\begin{aligned}\mathbf{P}^{(\ell+1/2)} &= \arg \min_{\mathbf{P} \mathbf{1}_m = \mathbf{a}} \text{KL}(\mathbf{P} \parallel \mathbf{P}^{(\ell)}), \\ \mathbf{P}^{(\ell+1)} &= \arg \min_{\mathbf{P}^\top \mathbf{1}_n = \mathbf{b}} \text{KL}(\mathbf{P} \parallel \mathbf{P}^{(\ell+1/2)})\end{aligned}$$

であり、行制約と列制約への KL 射影を交互に行うことに対応する。

注意 4.2.3: GPU 並列化

複数の入力対 $(\mathbf{a}_1, \mathbf{b}_1), \dots, (\mathbf{a}_N, \mathbf{b}_N)$ に対して同一コスト行列 $\mathbf{C}$ のもとでの計算は、行列 $\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_N]$, $\mathbf{B} = [\mathbf{b}_1, \dots, \mathbf{b}_N]$ を用いて

$$\mathbf{U}^{(\ell+1)} = \mathbf{A} \oslash (\mathbf{K} \mathbf{V}^{(\ell)}), \quad \mathbf{V}^{(\ell+1)} = \mathbf{B} \oslash (\mathbf{K}^\top \mathbf{U}^{(\ell+1)})$$

と行列-行列積でバッチ化でき、GPU 上で効率的に実行できる。

4.3 収束性

Sinkhorn アルゴリズムの収束は Hilbert 射影距離を用いて解析される。

定義 4.3.1: Hilbert 射影距離

正ベクトル $\mathbf{u}, \mathbf{u}' \in \mathbb{R}_{++}^n$ に対して、**Hilbert 射影距離** (Hilbert projective metric) を

$$\text{Hilbert}(\mathbf{u}, \mathbf{u}') \stackrel{\text{def}}{=} \log \max_{i,j} \frac{u_i u'_j}{u_j u'_i}$$

で定義する。 $\text{Hilbert}(\mathbf{u}, \mathbf{u}') = 0$ は $\mathbf{u}$ と $\mathbf{u}'$ が定数倍の関係にあることと同値である。これは射影空間 $\mathbb{R}_{++}^n / \sim$ 上の距離となる。

定理 4.3.2: Birkhoff の縮小定理

正行列 $\mathbf{K} \in \mathbb{R}_{++}^{n \times m}$ に対して、

$$\text{Hilbert}(\mathbf{K} \mathbf{v}, \mathbf{K} \mathbf{v}') \leq \lambda(\mathbf{K}) \text{Hilbert}(\mathbf{v}, \mathbf{v}')$$

が成り立つ。ここで $\lambda(\mathbf{K}) \in [0, 1)$ は **Birkhoff 縮小率**であり、

$$\lambda(\mathbf{K}) = \frac{\sqrt{\eta(\mathbf{K})} - 1}{\sqrt{\eta(\mathbf{K})} + 1}, \quad \eta(\mathbf{K}) = \max_{i,j,k,\ell} \frac{K_{i,k} K_{j,\ell}}{K_{j,k} K_{i,\ell}}$$

で定義される。Gibbs カーネル $K_{i,j} = e^{-C_{i,j}/\varepsilon}$ に対しては $\eta(\mathbf{K}) = e^{2\|\mathbf{C}\|_\infty/\varepsilon}$ であり、 ε が大きいほど $\lambda(\mathbf{K})$ は小さくなる (収束が速い)。

命題 4.3.3: Sinkhorn の線形収束

Sinkhorn アルゴリズムのスケーリングベクトルは、Hilbert 距離の意味で最適スケーリング $(\mathbf{u}^*, \mathbf{v}^*)$ に線形収束する：

$$\text{Hilbert}(\mathbf{u}^{(\ell)}, \mathbf{u}^*) = O(\lambda(\mathbf{K})^{2\ell}).$$

停止条件として、周辺分布の制約違反 $\|\mathbf{P}^{(\ell)} \mathbf{1}_m - \mathbf{a}\|_1$ の監視が実用的である。

4.4 数値安定性と対数領域計算

ε が小さいとき、Gibbs カーネルの成分 $K_{i,j} = e^{-C_{i,j}/\varepsilon}$ は機械精度のアンダーフローを起こしうる。この問題は、**対数領域** (log-domain) で計算を行うことで回避できる。

4.4.1 正則化問題の双対

命題 4.4.1: エントロピー正則化の双対問題

エントロピー正則化された最適輸送の双対問題は

$$L_{\mathbf{C}}^{\varepsilon}(\mathbf{a}, \mathbf{b}) = \max_{\mathbf{f} \in \mathbb{R}^n, \mathbf{g} \in \mathbb{R}^m} \langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{g}, \mathbf{b} \rangle - \varepsilon \sum_{i,j} e^{(f_i + g_j - C_{i,j})/\varepsilon}$$

で与えられる。ここで $(\mathbf{f}, \mathbf{g})$ とスケーリング変数の関係は $u_i = e^{f_i/\varepsilon}$, $v_j = e^{g_j/\varepsilon}$ である。

4.4.2 対数領域 Sinkhorn

対数領域では、Sinkhorn の反復を $(\mathbf{f}, \mathbf{g})$ に対する更新として書ける：

$$\begin{aligned} f_i^{(\ell+1)} &= \varepsilon \log a_i - \varepsilon \log \sum_j e^{(g_j^{(\ell)} - C_{i,j})/\varepsilon}, \\ g_j^{(\ell+1)} &= \varepsilon \log b_j - \varepsilon \log \sum_i e^{(f_i^{(\ell+1)} - C_{i,j})/\varepsilon}. \end{aligned}$$

これはプリミティブな Sinkhorn 反復 $\mathbf{u}^{(\ell+1)} = \mathbf{a} \odot (\mathbf{K} \mathbf{v}^{(\ell)})$ と $f_i = \varepsilon \log u_i$, $g_j = \varepsilon \log v_j$ を通じて等価である。

4.4.3 ソフト最小値と log-sum-exp

対数領域の反復は**ソフト最小値** (soft minimum) 演算子を用いて簡潔に表現できる。

定義 4.4.2: ソフト最小値

ベクトル $\mathbf{z} \in \mathbb{R}^n$ に対して、**ソフト最小値**を

$$\text{smin}_{\varepsilon} \mathbf{z} \stackrel{\text{def}}{=} -\varepsilon \log \sum_{i=1}^n e^{-z_i/\varepsilon}$$

で定義する。 $\varepsilon \rightarrow 0$ のとき $\text{smin}_\varepsilon \mathbf{z} \rightarrow \min_i z_i$ となる。

ソフト最小値を行方向・列方向に適用する演算子を $\text{smin}_\varepsilon^r$, $\text{smin}_\varepsilon^c$ と書くと、対数領域 Sinkhorn は

$$\begin{aligned} f_i^{(\ell+1)} &= \text{smin}_\varepsilon^r(\mathbf{C} - \mathbf{1}_n(\mathbf{g}^{(\ell)})^\top)_i + \varepsilon \log a_i, \\ g_j^{(\ell+1)} &= \text{smin}_\varepsilon^c(\mathbf{C} - \mathbf{f}^{(\ell+1)}\mathbf{1}_m^\top)_j + \varepsilon \log b_j \end{aligned}$$

と書ける。

注意 4.4.3: log-sum-exp の安定化

smin_ε の計算では、指数関数のオーバーフローを避けるために **log-sum-exp** トリックを用いる：

$$\text{smin}_\varepsilon \mathbf{z} = \underline{z} - \varepsilon \log \sum_i e^{-(z_i - \underline{z})/\varepsilon}$$

ここで $\underline{z} = \min_i z_i$ である。指数関数の引数が非正となるため、オーバーフローが回避される。

注意 4.4.4: 対数領域計算のトレードオフ

対数領域 Sinkhorn は任意の $\varepsilon > 0$ で安定であるが、各反復で nm 回の指数関数計算を要する。プリミティブな Sinkhorn（行列ベクトル積のみ）と比較して定数倍遅くなるが、 ε が小さい場合には不可欠である。

4.5 正則化された輸送コストの近似

L_C^ε は正則化によりバイアスを含む。実用上は、双対変数からの上界・下界を用いて非正則化コスト L_C を近似する。

命題 4.5.1: 双対変数からの下界

エントロピー正則化問題の最適双対変数 $(\mathbf{f}^*, \mathbf{g}^*)$ は $\mathbf{R}(\mathbf{C})$ に属し、

$$\langle \mathbf{f}^*, \mathbf{a} \rangle + \langle \mathbf{g}^*, \mathbf{b} \rangle \leq L_C(\mathbf{a}, \mathbf{b})$$

が成り立つ。すなわち、正則化双対変数の目的関数値は非正則化問題の最適値の**下界**を与える。

これを利用して、2種類の **Sinkhorn ダイバージェンス**を定義する：

$$\begin{aligned} S_C^{\varepsilon, \text{dual}}(\mathbf{a}, \mathbf{b}) &\stackrel{\text{def}}{=} \langle \mathbf{f}^*, \mathbf{a} \rangle + \langle \mathbf{g}^*, \mathbf{b} \rangle && \text{(下界),} \\ S_C^{\varepsilon, \text{primal}}(\mathbf{a}, \mathbf{b}) &\stackrel{\text{def}}{=} \langle \mathbf{C}, \mathbf{P}_\varepsilon \rangle && \text{(上界).} \end{aligned}$$

両者の差は $S_C^{\varepsilon, \text{primal}} - S_C^{\varepsilon, \text{dual}} = \varepsilon(H(\mathbf{P}_\varepsilon) + 1)$ であり、 $\varepsilon \rightarrow 0$ で消失する。

注意 4.5.2: $(\mathbf{a}, \mathbf{b})$ に関する凸性

$L_C^\varepsilon(\mathbf{a}, \mathbf{b})$ は $(\mathbf{a}, \mathbf{b})$ に関して凸であり, $\varepsilon > 0$ のとき微分可能で $\nabla_{\mathbf{a}} L_C^\varepsilon = \mathbf{f}^*$, $\nabla_{\mathbf{b}} L_C^\varepsilon = \mathbf{g}^*$ が成り立つ. この性質は Wasserstein 重心の計算などで重要である.