

セミナー発表原稿  
計算最適輸送

2026 年 4 月 14 日

# 目次

|                                   |    |
|-----------------------------------|----|
| 記号表                               | 2  |
| 第 1 章 Monge 問題から Sinkhorn アルゴリズムへ | 4  |
| 1.1 Monge 問題                      | 4  |
| 1.2 Kantorovich 緩和                | 6  |
| 1.3 双対問題                          | 8  |
| 1.4 古典的アルゴリズムとその限界                | 10 |
| 1.5 エントロピー正則化                     | 11 |
| 1.6 Sinkhorn アルゴリズム               | 12 |
| 1.7 収束性の保証                        | 13 |
| 1.8 数値安定性：対数領域 Sinkhorn           | 14 |
| 1.9 非正則化コストの近似                    | 15 |
| 1.10 まとめ                          | 15 |

# 記号表

## 一般記号

|                            |                                                                   |
|----------------------------|-------------------------------------------------------------------|
| $\mathcal{X}, \mathcal{Y}$ | 距離空間                                                              |
| $\mathbb{R}_+$             | $[0, \infty)$                                                     |
| $\mathbb{R}_{++}$          | $(0, \infty)$                                                     |
| $\mathcal{B}(\mathcal{X})$ | $\mathcal{X}$ のボレル $\sigma$ -代数 ( $\mathcal{B}(\mathcal{Y})$ も同様) |

## 測度

|                                    |                                                        |
|------------------------------------|--------------------------------------------------------|
| $\mathcal{M}_+^1(\mathcal{X})$     | $\mathcal{X}$ 上の確率測度の全体                                |
| $\delta_x$                         | 点 $x$ に質量 1 を集中させた Dirac 測度                            |
| $T_{\#}\alpha$                     | 可測写像 $T$ による $\alpha$ の押し出し (push-forward)             |
| $P_{\mathcal{X}}, P_{\mathcal{Y}}$ | 積空間 $\mathcal{X} \times \mathcal{Y}$ からの第 1・第 2 成分への射影 |

## 離散版

|                                                    |                                                                                           |
|----------------------------------------------------|-------------------------------------------------------------------------------------------|
| $\Sigma_n$                                         | 確率単体 $\{\mathbf{a} \in \mathbb{R}_+^n \mid \sum_i a_i = 1\}$ ( $n-1$ 次元)                  |
| $\mathbf{a} \in \Sigma_n, \mathbf{b} \in \Sigma_m$ | 輸送元・輸送先のヒストグラム                                                                            |
| $\mathbf{C} \in \mathbb{R}_+^{n \times m}$         | コスト行列 ( $C_{i,j}$ : ペン $i$ から $j$ への輸送コスト)                                                |
| $\mathbf{1}_n$                                     | 成分がすべて 1 の $n$ 次元ベクトル                                                                     |
| $\langle \cdot, \cdot \rangle$                     | フロベニウス内積 $\langle \mathbf{A}, \mathbf{B} \rangle = \text{tr}(\mathbf{A}^\top \mathbf{B})$ |
| $\odot, \oslash$                                   | 成分ごとの積 (アダマール積)・成分ごとの除算                                                                   |

## 最適輸送

|                                                 |                               |
|-------------------------------------------------|-------------------------------|
| $\mathcal{U}(\alpha, \beta)$                    | $\alpha$ と $\beta$ のカップリングの集合 |
| $\mathbf{U}(\mathbf{a}, \mathbf{b})$            | 離散版カップリング (輸送多面体)             |
| $\mathcal{L}_c(\alpha, \beta)$                  | Kantorovich 問題の最適値 (連続版)      |
| $\mathbf{L}_\mathbf{C}(\mathbf{a}, \mathbf{b})$ | Kantorovich 問題の最適値 (離散版)      |
| $\mathbf{R}(\mathbf{C})$                        | Kantorovich 双対ポテンシャルの実行可能集合   |

## エントロピー正則化

|                                              |                                                        |
|----------------------------------------------|--------------------------------------------------------|
| $H(\mathbf{P})$                              | 離散エントロピー $-\sum_{i,j} P_{i,j}(\log P_{i,j} - 1)$       |
| $\text{KL}(\mathbf{P} \parallel \mathbf{K})$ | KL ダイバージェンス                                            |
| $\mathbf{L}_\mathbf{C}^\varepsilon$          | エントロピー正則化された最適輸送の最適値                                   |
| $\text{smin}_\varepsilon$                    | ソフト最小値 $-\varepsilon \log \sum_i e^{-z_i/\varepsilon}$ |



## 第 1 章

# Monge 問題から Sinkhorn アルゴリズムへ

### 1.1 Monge 問題

「ある場所にある砂山を、最小の労力で別の場所に所定の形状で積み上げるには、各砂粒をどこに運べばよいか？」— 1781 年に Monge が提唱したこの問題は、次のように定式化される。

#### 定義 1.1.1: Dirac 測度

点  $x \in \mathcal{X}$  に対して、**Dirac 測度**  $\delta_x \in \mathcal{M}_+^1(\mathcal{X})$  を

$$\delta_x(A) \stackrel{\text{def}}{=} \begin{cases} 1 & x \in A, \\ 0 & x \notin A \end{cases} \quad (\forall A \in \mathcal{B}(\mathcal{X}))$$

で定義する。

全質量が点  $x$  に集中した確率測度である。

#### 定義 1.1.2: 押し出し (push-forward)

可測写像  $T: \mathcal{X} \rightarrow \mathcal{Y}$  と測度  $\mu \in \mathcal{M}_+^1(\mathcal{X})$  に対して、 $T$  による  $\mu$  の**押し出し**  $T_\# \mu \in \mathcal{M}_+^1(\mathcal{Y})$  を

$$(T_\# \mu)(A) \stackrel{\text{def}}{=} \mu(T^{-1}(A)) \quad (\forall A \in \mathcal{B}(\mathcal{Y}))$$

で定義する。


#### 定義 1.1.3: Monge 問題

確率測度  $\alpha \in \mathcal{M}_+^1(\mathcal{X})$ ,  $\beta \in \mathcal{M}_+^1(\mathcal{Y})$  とコスト関数  $c: \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}_+$  に対して、**Monge 問題**とは、

$$\inf_{T: \mathcal{X} \rightarrow \mathcal{Y}} \left\{ \int_{\mathcal{X}} c(x, T(x)) d\alpha(x) \mid T_\# \alpha = \beta \right\}$$

を求める問題である。

Monge の定式化の特徴は、輸送を写像  $T$  で記述する点にあり、各点  $x$  の質量は 1 つの行き先  $T(x)$  にしか送れない（質量の分割は許されない）。



$$T_{\#}\alpha = \beta \iff \alpha(T^{-1}(A)) = \beta(A) \quad (\forall A)$$

図 1.1 Monge 問題の概念図. 写像  $T$  が  $\mathcal{X}$  上の測度  $\alpha$  を  $\mathcal{Y}$  上の測度  $\beta$  に押し出す.

### 1.1.1 Monge 問題の本質的困難

Monge の定式化には 2 つの深刻な問題がある. 1 つ目は凸性に関わるため, 以下では  $\mathcal{Y}$  をベクトル空間 (例:  $\mathbb{R}^d$ ) に限定する.

#### 定義 1.1.4: 凸結合・凸集合

ベクトル空間  $V$  の元  $v_1, v_2 \in V$  と  $t \in [0, 1]$  に対して,  $tv_1 + (1-t)v_2$  を  $v_1$  と  $v_2$  の**凸結合**という. 部分集合  $S \subseteq V$  が**凸**であるとは, 任意の  $v_1, v_2 \in S$  の凸結合が再び  $S$  に属すること, すなわち

$$v_1, v_2 \in S, t \in [0, 1] \implies tv_1 + (1-t)v_2 \in S$$

が成り立つことをいう.

#### 注意 1.1.5: 写像空間への適用

以下で実行可能集合  $\mathcal{T}(\alpha, \beta)$  の凸性を議論するために, それが属する空間のベクトル空間構造を確認する.  $\mathcal{Y}$  がベクトル空間のとき,  $\mathcal{X}$  上の写像全体  $\mathcal{Y}^{\mathcal{X}}$  は点ごとの演算によりベクトル空間をなす. 写像  $T_1, T_2: \mathcal{X} \rightarrow \mathcal{Y}$  の凸結合はこの構造のもとで

$$(tT_1 + (1-t)T_2)(x) = tT_1(x) + (1-t)T_2(x) \quad (\forall x \in \mathcal{X})$$

と計算される. したがって  $\mathcal{Y}^{\mathcal{X}}$  の部分集合の凸性を問うことができる.

#### 困難 1: 実行可能集合の非凸性

Monge 問題の実行可能集合

$$\mathcal{T}(\alpha, \beta) \stackrel{\text{def}}{=} \{T: \mathcal{X} \rightarrow \mathcal{Y} \mid T \text{ は可測, } T_{\#}\alpha = \beta\}$$

は  $\mathcal{Y}^{\mathcal{X}}$  の部分集合であるが, 一般に**凸でない**. その理由は, 押し出し  $T_{\#}\alpha$  が写像  $T$  に関して**非線形**であることにある. すなわち,  $T_1, T_2 \in \mathcal{T}(\alpha, \beta)$  のとき  $T_{i\#}\alpha = \beta$  であるから  $t \cdot T_{1\#}\alpha + (1-t) \cdot T_{2\#}\alpha = t\beta + (1-t)\beta = \beta$

が成り立つが、凸結合の押し出しはこれと一致するとは限らない：

$$(tT_1 + (1-t)T_2)_\# \alpha \neq t \cdot T_{1\#} \alpha + (1-t) \cdot T_{2\#} \alpha \quad (\text{一般には}).$$

直観的には、押し出しは各点の**行き先の分布**を見る操作であり、行き先を点ごとに補間すると分布自体が変わってしまうためである。

#### 注意 1.1.6: 測地線凸性

ここでは  $\mathcal{Y}$  がベクトル空間の場合に限り凸性を議論した。  $\mathcal{Y}$  が一般の距離空間の場合、凸結合の代わりに 2 点間の測地線を用いた**測地線凸性** (geodesic convexity) で同様の議論が展開できる。

一般に凸でないため、凸最適化の手法が適用できず、大域的最適解の保証が困難になる。


### 困難 2：解の非存在

写像による輸送では、質量の**分割**が許されない。すなわち、 $x$  の質量は  $T(x)$  という 1 点にすべて送らなければならない。このため、輸送元の測度が輸送先の測度より「粗い」場合に問題が生じる。

#### 例 1.1.7: Monge 写像が存在しない場合

$\alpha = \delta_0$  (原点に全質量を集中),  $\beta = \frac{1}{2}\delta_{-1} + \frac{1}{2}\delta_1$  ( $-1$  と  $1$  に半分ずつ配置) を考える。

$T_\# \delta_0 = \delta_{T(0)}$  は 1 点に集中した測度であるから、 $\delta_{T(0)} = \frac{1}{2}\delta_{-1} + \frac{1}{2}\delta_1$  を満たす  $T(0)$  は存在しない。



1 点の質量を 2 箇所に分割して送ることができないため、実行可能な写像  $T$  自体が存在しない。

この困難を解消するのが、次節の Kantorovich による緩和である。

## 1.2 Kantorovich 緩和

### 1.2.1 鍵となるアイデア

Kantorovich (1942) の革命的なアイデアは、Monge の写像  $T$  (各点  $x$  の質量を 1 つの行き先に集中させる) を、**輸送計画** (質量を複数の行き先に分割して送ることを許す) に置き換えることである。Monge の定式化では質量の分割が禁じられていたが、Kantorovich はこの制約を外し、 $\mathcal{X} \times \mathcal{Y}$  上の結合測度 (カップリング) として輸送計画を定式化した。

## 1.2.2 カップリング

### 定義 1.2.1: カップリング

確率測度  $\alpha \in \mathcal{M}_+^1(\mathcal{X})$  と  $\beta \in \mathcal{M}_+^1(\mathcal{Y})$  に対して,  $\alpha$  と  $\beta$  のカップリングの集合を

$$\mathcal{U}(\alpha, \beta) \stackrel{\text{def}}{=} \{ \pi \in \mathcal{M}_+^1(\mathcal{X} \times \mathcal{Y}) \mid (P_{\mathcal{X}})_{\#} \pi = \alpha, (P_{\mathcal{Y}})_{\#} \pi = \beta \}$$

で定義する. ここで  $P_{\mathcal{X}}: \mathcal{X} \times \mathcal{Y} \rightarrow \mathcal{X}$ ,  $P_{\mathcal{Y}}: \mathcal{X} \times \mathcal{Y} \rightarrow \mathcal{Y}$  はそれぞれ第 1・第 2 成分への射影である.

すなわち,  $\pi$  の周辺分布がそれぞれ  $\alpha, \beta$  に一致することを要求する.

■離散版での解釈. ヒストグラム  $\mathbf{a} \in \Sigma_n$ ,  $\mathbf{b} \in \Sigma_m$  に対して, 離散的なカップリングは  $n \times m$  の非負行列  $\mathbf{P}$  で表され,

$$\mathcal{U}(\mathbf{a}, \mathbf{b}) \stackrel{\text{def}}{=} \{ \mathbf{P} \in \mathbb{R}_+^{n \times m} \mid \mathbf{P} \mathbf{1}_m = \mathbf{a}, \mathbf{P}^\top \mathbf{1}_n = \mathbf{b} \}.$$

$P_{i,j}$  は「輸送元のビン  $i$  から輸送先のビン  $j$  へ送られる質量」を表す.




図 1.2 Monge 写像と Kantorovich カップリングの対比. Monge 写像は各点を 1 つの行き先に送るが, Kantorovich カップリングは質量の分割を許す.

■Monge 写像との対比.

## 1.2.3 Kantorovich 問題

### 定義 1.2.2: Kantorovich 問題

確率測度  $\alpha \in \mathcal{M}_+^1(\mathcal{X})$ ,  $\beta \in \mathcal{M}_+^1(\mathcal{Y})$ , コスト関数  $c: \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}_+$  に対して, **Kantorovich 問題**とは

$$\mathcal{L}_c(\alpha, \beta) \stackrel{\text{def}}{=} \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\pi(x, y)$$

を求める問題である. 離散版は

$$L_C(\mathbf{a}, \mathbf{b}) \stackrel{\text{def}}{=} \min_{\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})} \langle \mathbf{C}, \mathbf{P} \rangle.$$

### 1.2.4 なぜ Kantorovich 緩和が優れているか

Kantorovich の定式化は Monge 問題の困難をすべて解消する:

1. **凸性**:  $\mathcal{U}(\alpha, \beta)$  は凸集合であり, 目的関数は  $\pi$  に関して線形. よって**凸最適化問題**である.
2. **線形計画**: 離散版は  $nm$  変数の**線形計画問題** (LP) であり, 単体法や内点法で原理的に解ける.
3. **解の存在**: 離散版では  $\mathbf{U}(\mathbf{a}, \mathbf{b})$  は  $\mathbb{R}^{n \times m}$  の有界閉集合であるからコンパクトであり, 連続関数の最小値が達成される. 積  $\mathbf{a}\mathbf{b}^\top$  が常にカップリングの 1 つを与えるため実行可能集合は空でなく, 最適解  $\mathbf{P}^*$  が常に存在する.

### 1.2.5 Monge 問題の緩和としての位置づけ

Monge 写像  $T$  に対して,  $(\text{Id}, T): \mathcal{X} \rightarrow \mathcal{X} \times \mathcal{Y}$ ,  $x \mapsto (x, T(x))$  により  $\pi_T = (\text{Id}, T)_\# \alpha$  とおくと  $\pi_T \in \mathcal{U}(\alpha, \beta)$  となり,

$$\mathcal{L}_c(\alpha, \beta) \leq \inf_T \left\{ \int_{\mathcal{X}} c(x, T(x)) d\alpha(x) \mid T_\# \alpha = \beta \right\}.$$

Kantorovich 問題は Monge 問題の緩和であり, Monge 写像による輸送は「 $\pi$  が  $T$  のグラフ上に集中している」カップリングの特殊な場合である.

## 1.3 双対問題

Kantorovich 問題 (定義 1.2.2) は線形計画であるから, LP 双対理論を適用できる. 双対問題は最適輸送の理論的理解にも計算手法にも重要な役割を果たす.

### 1.3.1 ラグランジュ双対の導出

離散版 Kantorovich 問題の等式制約に対するラグランジュ乗数を  $\mathbf{f} \in \mathbb{R}^n$ ,  $\mathbf{g} \in \mathbb{R}^m$  とおくと, ラグランジュ関数は

$$L(\mathbf{P}, \mathbf{f}, \mathbf{g}) = \langle \mathbf{C}, \mathbf{P} \rangle + \langle \mathbf{f}, \mathbf{a} - \mathbf{P}\mathbf{1}_m \rangle + \langle \mathbf{g}, \mathbf{b} - \mathbf{P}^\top \mathbf{1}_n \rangle.$$

これを整理すると

$$L = \langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{g}, \mathbf{b} \rangle + \langle \mathbf{C} - \mathbf{f}\mathbf{1}_m^\top - \mathbf{1}_n\mathbf{g}^\top, \mathbf{P} \rangle.$$

$\mathbf{P} \geq 0$  のもとで  $L$  を  $\mathbf{P}$  について最小化すると、第3項が非負（すなわち  $f_i + g_j \leq C_{i,j}, \forall i, j$ ）のとき最小値は  $\langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{g}, \mathbf{b} \rangle$ ，そうでなければ  $-\infty$  となる。

### 1.3.2 Kantorovich 双対定理

#### 定理 1.3.1: Kantorovich 双対定理（離散版）

ヒストグラム  $\mathbf{a} \in \Sigma_n$ ,  $\mathbf{b} \in \Sigma_m$ , コスト行列  $\mathbf{C} \in \mathbb{R}_+^{n \times m}$  に対して,

$$\underbrace{\min_{\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})} \langle \mathbf{C}, \mathbf{P} \rangle}_{\text{主問題 (輸送計画の最適化)}} = \underbrace{\max_{\substack{(\mathbf{f}, \mathbf{g}) \in \mathbb{R}^n \times \mathbb{R}^m \\ f_i + g_j \leq C_{i,j} \quad \forall i, j}} \langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{g}, \mathbf{b} \rangle}_{\text{双対問題 (ポテンシャルの最適化)}}$$

が成り立つ。

線形計画の強双対性による。

双対実行可能集合を  $\mathbf{R}(\mathbf{C}) = \{(\mathbf{f}, \mathbf{g}) \mid f_i + g_j \leq C_{i,j}, \forall i, j\}$  と書く。

### 1.3.3 相補性条件

主問題と双対問題の最適解の間には重要な関係がある。

#### 命題 1.3.2: 相補性条件

$\mathbf{P}^*$  と  $(\mathbf{f}^*, \mathbf{g}^*)$  がそれぞれ主問題と双対問題の最適解ならば,

$$P_{i,j}^* > 0 \implies f_i^* + g_j^* = C_{i,j}$$

が成り立つ。

最適輸送計画で正の質量が輸送される経路では、双対ポテンシャルの和がコストに一致する。

*Proof.* 強双対性から  $\langle \mathbf{C}, \mathbf{P}^* \rangle = \langle \mathbf{f}^*, \mathbf{a} \rangle + \langle \mathbf{g}^*, \mathbf{b} \rangle$ . 主問題の制約を用いると  $\langle \mathbf{C} - \mathbf{f}^* \mathbf{1}_m^\top - \mathbf{1}_n \mathbf{g}^{*\top}, \mathbf{P}^* \rangle = 0$ .  $\mathbf{P}^* \geq 0$  かつ  $C_{i,j} - f_i^* - g_j^* \geq 0$  であるから、各成分の積  $P_{i,j}^* (C_{i,j} - f_i^* - g_j^*) = 0$  がすべての  $(i, j)$  で成り立つ。□

### 1.3.4 双対問題の経済学的解釈

双対問題には次の直感的な解釈がある。

輸送業者が、倉庫  $i$  での集荷料金  $f_i$ , 工場  $j$  への配送料金  $g_j$  を設定し、元の輸送会社に代わって輸送を引き受けるとする。輸送会社がこの契約を受け入れるためには、どの経路でも業者の料金が自前のコスト以下でなければならない:  $f_i + g_j \leq C_{i,j}$ . この条件のもとで収入  $\langle \mathbf{f}, \mathbf{a} \rangle + \langle \mathbf{g}, \mathbf{b} \rangle$  を最大化するのが双対問題であり、その最適値が最適輸送コストに一致する。

## 1.4 古典的アルゴリズムとその限界

Kantorovich 問題（定義 1.2.2）は線形計画であるから，原理的には単体法や内点法で解ける．さらに，最適輸送の特殊構造を利用した効率的な手法が開発されてきた．

### 1.4.1 線形計画としての構造

行列  $\mathbf{P}$  をベクトル  $\mathbf{p} \in \mathbb{R}^{nm}$  に並べ直すと，Kantorovich 問題は標準形の線形計画

$$\min_{\mathbf{p} \in \mathbb{R}_+^{nm}} \mathbf{c}^\top \mathbf{p} \\ \mathbf{A}\mathbf{p} = [\mathbf{a}^\top, \mathbf{b}^\top]^\top$$

となる．制約行列  $\mathbf{A} \in \mathbb{R}^{(n+m) \times nm}$  の階数は  $n + m - 1$  である（行制約の総和と列制約の総和がともに 1 となるため， $n + m$  本の制約のうち 1 本が冗長）．したがって，輸送多面体の頂点は  $n + m - 1$  個以下の非零成分を持つ．

### 1.4.2 古典的手法の概観

■ネットワーク単体法 輸送多面体の頂点間を移動しながら最適解を探索する．各反復では，(i) 現在の頂点に相補的な双対変数を構成し，(ii) 双対実行可能性を確認し，(iii) 違反する辺を追加して閉路に沿った流量調整を行う．多項式時間で停止することが Orlin (1997) により証明されている．

■オークションアルゴリズム Bertsekas (1981) による双対的手法． $\varepsilon$ -相補性条件を維持しながら双対変数  $\mathbf{g}$  を逐次更新する． $\varepsilon$ -スケールリングにより  $O(n^3 \log \|\mathbf{C}\|_\infty)$  の計算量．

■双対上昇法 双対変数  $(\mathbf{f}, \mathbf{g})$  を直接改善する手法．ハンガリアン法はこの枠組みの代表例である．

### 1.4.3 計算量の壁

これらの古典的手法はいずれも厳密解を与えるが，実用上の問題は計算量である：

| 手法                              | 計算量                                           |
|---------------------------------|-----------------------------------------------|
| LP 内点法（一般的な解法）                  | $O(n^3 m^3)$ 程度                               |
| ネットワーク単体法                       | $O(n^3 \log n \log(n \ \mathbf{C}\ _\infty))$ |
| オークション（ $\varepsilon$ -スケールリング） | $O(n^3 \log \ \mathbf{C}\ _\infty)$           |

$n = m = 1000$  程度で  $nm = 10^6$  変数の LP となり，画像処理（ $n \sim 10^4 - 10^6$ ）や機械学習の応用では  $n^3$  のオーダーは実用に耐えない．

問い：厳密解でなく近似解で良いなら，もっと速い手法はないか？

この問いへの回答が，次節のエントロピー正則化である．

## 1.5 エントロピー正則化

### 1.5.1 着想：エントロピー項を加える

目的関数にエントロピーの**正則化項**を加えることで、問題を厳密に凸化し、かつ効率的に解ける構造を持たせる。エントロピーが高い（質量が分散した）輸送計画を優遇する効果がある。

行列  $\mathbf{P} \in \mathbb{R}_+^{n \times m}$  の離散エントロピーを

$$H(\mathbf{P}) \stackrel{\text{def}}{=} - \sum_{i,j} P_{i,j} (\log P_{i,j} - 1)$$

とする。ただし  $0 \log 0 = 0$  と約束する。対応する負エントロピー  $-H$  は狭義凸関数である（各成分  $-x(\log x - 1)$  が  $x > 0$  で狭義凸であることによる）。勾配は  $\partial(-H)/\partial P_{i,j} = \log P_{i,j}$  と簡潔になる。

#### 定義 1.5.1: エントロピー正則化された最適輸送

正則化パラメータ  $\varepsilon > 0$  に対して、**エントロピー正則化された最適輸送問題**を

$$L_{\mathbf{C}}^{\varepsilon}(\mathbf{a}, \mathbf{b}) \stackrel{\text{def}}{=} \min_{\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})} \underbrace{\langle \mathbf{C}, \mathbf{P} \rangle}_{\text{輸送コスト}} \underbrace{- \varepsilon H(\mathbf{P})}_{\text{正則化項}}$$

で定義する。

目的関数は狭義凸であるから、最適解  $\mathbf{P}_{\varepsilon}$  は一意に存在する。

### 1.5.2 正則化パラメータ $\varepsilon$ の役割

$\varepsilon$  は2つの極限を補間する：

- $\varepsilon \rightarrow 0$  :  $\mathbf{P}_{\varepsilon}$  は非正則化問題の最適解（のうちエントロピー最大のもの）に収束。
- $\varepsilon \rightarrow +\infty$  :  $\mathbf{P}_{\varepsilon}$  は積測度  $\mathbf{a}\mathbf{b}^{\top}$  に収束（輸送元と輸送先を独立に結合する最も「ぼやけた」カップリング）。

### 1.5.3 KL ダイバージェンスによる再定式化

#### 定義 1.5.2: Gibbs カーネル

コスト行列  $\mathbf{C}$  と  $\varepsilon > 0$  に対して、**Gibbs カーネル**を  $K_{i,j} \stackrel{\text{def}}{=} e^{-C_{i,j}/\varepsilon}$  で定義する。

#### 定義 1.5.3: KL ダイバージェンス

非負行列  $\mathbf{P}, \mathbf{K} \in \mathbb{R}_+^{n \times m}$  に対して、

$$\text{KL}(\mathbf{P} \parallel \mathbf{K}) \stackrel{\text{def}}{=} \sum_{i,j} \left( P_{i,j} \log \frac{P_{i,j}}{K_{i,j}} - P_{i,j} + K_{i,j} \right)$$

とする．ただし  $0 \log(0/K_{i,j}) = 0$  と約束する．

$KL \geq 0$  であり，等号は  $\mathbf{P} = \mathbf{K}$  のときに限る．

Gibbs カーネルを用いると，正則化問題は **KL 射影** として書き直せる：

$$\mathbf{P}_\varepsilon = \arg \min_{\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})} KL(\mathbf{P} \parallel \mathbf{K}).$$

すなわち， $\mathbf{P}_\varepsilon$  は Gibbs カーネル  $\mathbf{K}$  のカップリング集合  $\mathbf{U}(\mathbf{a}, \mathbf{b})$  への KL 射影（集合内で  $\mathbf{K}$  に最も近い点）である．

## 1.6 Sinkhorn アルゴリズム

### 1.6.1 最適解の構造：スケーリング形式

正則化問題の最適解は，次の特殊な構造を持つ．

#### 命題 1.6.1: 最適解のスケーリング形式

最適解  $\mathbf{P}_\varepsilon$  は

$$(P_\varepsilon)_{i,j} = u_i K_{i,j} v_j$$

の形で表される．行列形式では  $\mathbf{P}_\varepsilon = \text{diag}(\mathbf{u}) \mathbf{K} \text{diag}(\mathbf{v})$ ．

*Proof.* ラグランジュ関数の  $P_{i,j} > 0$  における一次条件  $C_{i,j} + \varepsilon \log P_{i,j} - f_i - g_j = 0$  を解くと，

$$P_{i,j} = e^{f_i/\varepsilon} \cdot e^{-C_{i,j}/\varepsilon} \cdot e^{g_j/\varepsilon} = u_i K_{i,j} v_j.$$

ここで  $u_i = e^{f_i/\varepsilon}$ ， $v_j = e^{g_j/\varepsilon}$  とおいた．エントロピー項により目的関数の勾配は  $P_{i,j} \rightarrow 0^+$  で  $-\infty$  に発散するため，境界  $P_{i,j} = 0$  で最小値を取ることはなく，すべての成分で  $P_{i,j} > 0$  が成り立つ．  $\square$

### 1.6.2 周辺分布制約からの反復

$\mathbf{P}_\varepsilon = \text{diag}(\mathbf{u}) \mathbf{K} \text{diag}(\mathbf{v})$  に周辺分布制約を代入すると，

$$\mathbf{u} \odot (\mathbf{K} \mathbf{v}) = \mathbf{a}, \quad \mathbf{v} \odot (\mathbf{K}^\top \mathbf{u}) = \mathbf{b}$$

が得られる（ $\odot$  は成分ごとの積）．Sinkhorn アルゴリズムは，この 2 つの条件を**交互**に満たすよう  $\mathbf{u}$  と  $\mathbf{v}$  を更新する．

### Algorithm 1

**Input:**  $\mathbf{a} \in \Sigma_n, \mathbf{b} \in \Sigma_m, \mathbf{K} = e^{-\mathbf{C}/\varepsilon}$ , 反復回数  $L$

**Output:** スケーリングベクトル  $\mathbf{u}, \mathbf{v}$

1.  $\mathbf{v}^{(0)} \leftarrow \mathbf{1}_m$
2. **for**  $\ell = 0, 1, \dots, L-1$  **do**:
3.    $\mathbf{u}^{(\ell+1)} \leftarrow \mathbf{a} \oslash (\mathbf{K}\mathbf{v}^{(\ell)})$  (行制約を満たす)
4.    $\mathbf{v}^{(\ell+1)} \leftarrow \mathbf{b} \oslash (\mathbf{K}^\top \mathbf{u}^{(\ell+1)})$  (列制約を満たす)

ここで  $\oslash$  は成分ごとの除算  $((\mathbf{a} \oslash \mathbf{b})_i = a_i/b_i)$ . 各反復は行列ベクトル積 2 回で  $O(nm)$ .

### 1.6.3 Bregman 射影としての解釈

$\mathbf{P}^{(0)} = \mathbf{K}$  (Gibbs カーネル) を初期点とすると, Sinkhorn の各ステップは KL ダイバージェンスに関する交互射影と解釈できる:

$$\begin{aligned} \mathbf{P}^{(\ell+1/2)} &= \arg \min_{\mathbf{P} \mathbf{1}_m = \mathbf{a}} \text{KL}(\mathbf{P} \parallel \mathbf{P}^{(\ell)}) && \text{(行制約への射影),} \\ \mathbf{P}^{(\ell+1)} &= \arg \min_{\mathbf{P}^\top \mathbf{1}_n = \mathbf{b}} \text{KL}(\mathbf{P} \parallel \mathbf{P}^{(\ell+1/2)}) && \text{(列制約への射影).} \end{aligned}$$

### 1.6.4 GPU 並列化との親和性

Sinkhorn の核心的演算は行列ベクトル積  $\mathbf{K}\mathbf{v}$  と  $\mathbf{K}^\top \mathbf{u}$  であり, これは高度に並列化可能である. さらに, 複数の入力対  $(\mathbf{a}_k, \mathbf{b}_k)$  に対して同一コスト行列  $\mathbf{C}$  のもとでの計算は, 行列-行列積でバッチ化できる:

$$\mathbf{U}^{(\ell+1)} = \mathbf{A} \oslash (\mathbf{K}\mathbf{V}^{(\ell)}), \quad \mathbf{V}^{(\ell+1)} = \mathbf{B} \oslash (\mathbf{K}^\top \mathbf{U}^{(\ell+1)}).$$

古典的アルゴリズム (ネットワーク単体法等) は本質的に逐次的であり, この並列性が Sinkhorn の最大の実用的優位点である.

## 1.7 収束性の保証

### 1.7.1 Hilbert 射影距離

Sinkhorn の収束解析には Hilbert 射影距離が用いられる.

#### 定義 1.7.1: Hilbert 射影距離

正ベクトル  $\mathbf{u}, \mathbf{u}' \in \mathbb{R}_{++}^n$  に対して,

$$\text{Hilbert}(\mathbf{u}, \mathbf{u}') \stackrel{\text{def}}{=} \log \max_{i,j} \frac{u_i u'_j}{u_j u'_i}.$$

$\text{Hilbert}(\mathbf{u}, \mathbf{u}') = 0$  は  $\mathbf{u}$  と  $\mathbf{u}'$  が定数倍の関係にあることと同値であり, 射影空間  $\mathbb{R}_{++}^n / \mathbb{R}_{++}$  上の距離を与える.

### 1.7.2 Birkhoff の縮小定理

#### 定理 1.7.2: Birkhoff の縮小定理

正行列  $\mathbf{K} \in \mathbb{R}_{++}^{n \times m}$  に対して,

$$\text{Hilbert}(\mathbf{K}\mathbf{v}, \mathbf{K}\mathbf{v}') \leq \lambda(\mathbf{K}) \text{Hilbert}(\mathbf{v}, \mathbf{v}')$$

が成り立つ. Birkhoff 縮小率は  $\lambda(\mathbf{K}) = \frac{\sqrt{\eta}-1}{\sqrt{\eta}+1} \in [0, 1)$  であり,  $\eta = \max_{i,j,k,\ell} \frac{K_{i,k}K_{j,\ell}}{K_{j,k}K_{i,\ell}}$  で定まる.

Gibbs カーネル  $K_{i,j} = e^{-C_{i,j}/\varepsilon}$  に対しては  $\eta = e^{2\|\mathbf{C}\|_\infty/\varepsilon}$  であり,  $\varepsilon$  が大きいほど  $\lambda$  が小さくなり収束が速い.

### 1.7.3 Sinkhorn の線形収束

定理 1.7.2 を反復に適用すると,

$$\text{Hilbert}(\mathbf{u}^{(\ell)}, \mathbf{u}^*) = O(\lambda(\mathbf{K})^{2\ell})$$

が得られ, 線形収束 (幾何級数的収束) が保証される.

実用的な停止条件としては, 周辺分布の制約違反  $\|\mathbf{P}^{(\ell)}\mathbf{1}_m - \mathbf{a}\|_1$  の監視が推奨される.

## 1.8 数値安定性: 対数領域 Sinkhorn

### 1.8.1 アンダーフロー問題

$\varepsilon$  が小さいとき,  $K_{i,j} = e^{-C_{i,j}/\varepsilon}$  は機械精度を下回る. 例えば  $C_{i,j} = 10$ ,  $\varepsilon = 0.01$  では  $K_{i,j} = e^{-1000} \approx 10^{-434}$  であり, 64 ビット浮動小数点で表現不能 (アンダーフロー) となる.

### 1.8.2 対数領域への変換

$u_i = e^{f_i/\varepsilon}$ ,  $v_j = e^{g_j/\varepsilon}$  として対数領域の変数  $(\mathbf{f}, \mathbf{g})$  で反復を記述する:

$$\begin{aligned} f_i^{(\ell+1)} &= \varepsilon \log a_i - \varepsilon \log \sum_j e^{(g_j^{(\ell)} - C_{i,j})/\varepsilon}, \\ g_j^{(\ell+1)} &= \varepsilon \log b_j - \varepsilon \log \sum_i e^{(f_i^{(\ell+1)} - C_{i,j})/\varepsilon}. \end{aligned}$$

### 1.8.3 ソフト最小値と log-sum-exp 安定化

上の反復はソフト最小値  $\text{smin}_\varepsilon \mathbf{z} \stackrel{\text{def}}{=} -\varepsilon \log \sum_i e^{-z_i/\varepsilon}$  を用いて簡潔に書ける.  $\varepsilon \rightarrow 0$  で  $\text{smin}_\varepsilon \mathbf{z} \rightarrow \min_i z_i$  となる.

log-sum-exp トリックにより数値安定化する:

$$\text{smin}_\varepsilon \mathbf{z} = \underline{z} - \varepsilon \log \sum_i e^{-(z_i - \underline{z})/\varepsilon}, \quad \underline{z} = \min_i z_i.$$

指数関数の引数が非正となるため、オーバーフローが回避される。

#### 1.8.4 トレードオフ

対数領域 Sinkhorn は任意の  $\varepsilon > 0$  で安定に動作するが、各反復で  $nm$  回の指数関数計算を要する。プリミティブな Sinkhorn（行列ベクトル積のみ）と比較して定数倍遅くなるが、 $\varepsilon$  が小さい場合には不可欠な安定化手法である。

### 1.9 非正則化コストの近似

$L_C^\varepsilon$  はエントロピー項によりバイアスを含む。双対変数を用いて、非正則化コスト  $L_C$  の上界・下界が得られる。

#### 命題 1.9.1: 非正則化コストの近似

正則化問題の最適双対変数  $(\mathbf{f}^*, \mathbf{g}^*)$  は  $\mathbf{R}(\mathbf{C})$  に属し、

$$\langle \mathbf{f}^*, \mathbf{a} \rangle + \langle \mathbf{g}^*, \mathbf{b} \rangle \leq L_C(\mathbf{a}, \mathbf{b}) \leq \langle \mathbf{C}, \mathbf{P}_\varepsilon \rangle$$

が成り立つ。

*Proof.* 上界： $\mathbf{P}_\varepsilon \in \mathbf{U}(\mathbf{a}, \mathbf{b})$  は非正則化問題の実行可能解であるから、 $L_C(\mathbf{a}, \mathbf{b}) \leq \langle \mathbf{C}, \mathbf{P}_\varepsilon \rangle$ 。

下界：正則化問題の KKT 条件より  $f_i^* + g_j^* = C_{i,j} + \varepsilon \log(P_\varepsilon)_{i,j}$ 。  $\mathbf{P}_\varepsilon$  はカップリングであるから  $(P_\varepsilon)_{i,j} \leq a_i \leq 1$  が成り立ち、 $\log(P_\varepsilon)_{i,j} \leq 0$ 。 よって  $f_i^* + g_j^* \leq C_{i,j}$ ，すなわち  $(\mathbf{f}^*, \mathbf{g}^*) \in \mathbf{R}(\mathbf{C})$ 。非正則化問題の双対定理（定理 1.3.1）から下界が従う。  $\square$

左辺と右辺の差（近似誤差）を評価する。KKT 条件と周辺分布制約から

$$\langle \mathbf{f}^*, \mathbf{a} \rangle + \langle \mathbf{g}^*, \mathbf{b} \rangle = \sum_{i,j} (f_i^* + g_j^*) (P_\varepsilon)_{i,j} = \langle \mathbf{C}, \mathbf{P}_\varepsilon \rangle + \varepsilon \sum_{i,j} (P_\varepsilon)_{i,j} \log(P_\varepsilon)_{i,j}$$

であり、 $\sum_{i,j} (P_\varepsilon)_{i,j} = 1$  と  $H(\mathbf{P}) = -\sum P_{i,j} \log P_{i,j} + \sum P_{i,j}$  から、近似誤差は  $\varepsilon(H(\mathbf{P}_\varepsilon) - 1)$  となる。 $\varepsilon$  を小さく取るほど近似は精密になるが、収束は遅くなり数値安定性も低下する。このトレードオフの制御が実用上の鍵である。

### 1.10 まとめ

本セミナーの議論を振り返る。



図 1.3 Monge 問題から Sinkhorn アルゴリズムに至る議論の流れ.